

Universidad Nacional del Centro de la Provincia De Buenos Aires
Facultad de Ciencias Exactas - Departamento de Computación y Sistemas
Ingeniería de Sistemas

Un prototipo de ambiente Dew para etiquetado y clasificación de ganado

por
Cristian David Roldan

Director: Dr. Matías Hirsch

Co-Director: Dr. Juan Toloza

Trabajo final de carrera presentado como requisito parcial
para optar por el título de
Ingeniero de Sistemas

Tandil, Buenos Aires, Argentina

Resumen

Agradecimientos

Contents

1	Introducción	1
1.1	Uso de tecnología de la información en granjas	1
1.2	Importancia de BCS y la necesidad de mejorar la alimentación de las vacas	2
1.3	Motivación	2
1.3.1	Escasez de prototipos	3
1.4	Propuesta	4
1.4.1	Objetivo	4
1.4.2	Contexto	5
1.4.3	Desafíos actuales	6
1.4.4	Solución propuesta	6
2	Trabajos relacionados	9
2.1	Importancia y avances de la IA para calcular BCS	9
2.2	Importancia de dew computing	10
2.3	Comparaciones	11
2.3.1	Limitaciones halladas en trabajos relacionados	12
2.3.2	Mejoras de mi propuesta	13
3	Requerimientos	15
3.1	Requerimientos funcionales	15
3.2	Casos de uso	16

CONTENTS

3.2.1	Login	16
3.2.2	Sesión de calificación	17
3.2.3	Sistema de notificación de imágenes	18
3.2.4	Calificadores	19
3.2.5	Observadores	19
3.2.6	Reportes	19
4	Diseño	21
4.1	Login	21
4.2	Sesión de calificación	22
4.3	Sistema de notificación de imágenes	24
4.3.1	Recepción y Almacenamiento de Imágenes	24
4.3.2	Gestor de mensajes de imágenes	25
4.3.3	Calificadores	26
4.3.4	Observador	27
4.4	Reportes	28
4.4.1	Observador	30
4.4.2	Calificador	30
4.5	Implementación	31
4.5.1	Tecnologías y Bibliotecas Utilizadas	31
4.5.2	Configuración del sistema	31
4.5.2.1	Configuración del Servidor	32
4.5.2.2	Configuración de la aplicación móvil	33
4.5.2.3	Configuración de docker	34
4.5.3	Modelo de base de datos	34
5	Resultados	39
5.1	Pantalla de Inicio de Sesión (Login)	39
5.2	Calificador	40
5.3	Sistema de Notificación de Imágenes	40

CONTENTS

5.4	Reportes Generados	41
5.5	Rendimientos del sistema	41
5.5.1	Tiempos de Predicción	42
6	Conclusiones, Limitaciones y Trabajos Futuros	43
6.1	Login	43
6.2	Calificador	43
6.3	Arribo de imágenes de vacas	44
6.4	Aplicación batch	44
6.5	Calificador	44
6.6	Observadores	45
6.7	Objetivos futuros	45
	Bibliography	47

CONTENTS

List of Figures

4.1	Componentes del sistema	22
4.2	Diagrama de componentes - login	22
4.3	Diagrama de componentes - sesión de calificación	23
4.4	Diagrama de componentes - imágenes	25
4.5	Diagrama de componentes: calificador	26
4.6	Diagrama de componentes - Observadores	27
4.7	Diagrama de componentes - Observadores en detalle	29
4.8	Diagrama de componentes - reporte de observadores	30
4.9	Diagrama de componentes - reporte de calificadores	31

LIST OF FIGURES

List of Tables

Introducción

1.1 Uso de tecnología de la información en granjas

La adopción de tecnología en las granjas tiene como objetivo transformar la forma en que se gestionan y optimizan las operaciones agropecuarias, permitiendo una mayor eficiencia, sostenibilidad y precisión en la producción. En el ámbito de la ganadería lechera, por ejemplo, se han diseñado sistemas avanzados para la detección del estro en vacas, como lo describe el artículo de Li et al. [2010]. Este sistema utiliza tecnología inalámbrica Zigbee y sensores de infrarrojos para monitorear la temperatura corporal y el movimiento del ganado, tratando de mejorar la precisión en la detección del estro y reduciendo la carga laboral.

Por otro lado, en un contexto más amplio, la adopción de tecnologías como la Internet de las Cosas (IoT) y Edge Computing (EC) son cruciales en la industria láctea para poder adaptarse a un mercado globalizado. Según Alonso et al. [2020], estas tecnologías permiten digitalizar toda la cadena de valor, optimizando procesos, garantizando la trazabilidad y asegurando la calidad del producto final, lo que es fundamental en un entorno de agricultura inteligente.

Finalmente, la aplicación de técnicas de Deep Learning (DL) también está revolucionando la ganadería. En Mahmud et al. [2021] destacan cómo DL se está utilizando para la automatización de tareas como la identificación y el monitoreo de la salud del ganado, aunque aún existen desafíos significativos, especialmente en el monitoreo en tiempo real y el rastreo de movimientos en condiciones de granja.

En conjunto, estos avances subrayan el papel esencial de la tecnología en la modernización de la agricultura y la ganadería, impulsando mejoras en la productividad.

1.2 Importancia de BCS y la necesidad de mejorar la alimentación de las vacas

Entre varias variables de importancia productiva, económica y ambiental, existe consenso en que la identificación de la condición corporal (BCS, por sus siglas en inglés) y los cambios en esta son los mejores indicadores de las reservas nutricionales de una vaca, superando al peso vivo o al cambio de peso vivo. Esto se debe a que estas últimas variables pueden verse afectadas por factores como el peso fetal y el llenado del rumen, como se describió tempranamente en la lechería Wildman et al. [1982] y en el ganado bovino Richards et al. [1986]. A lo largo del tiempo, se han acumulado evidencias sobre la efectividad del sistema visual de condición corporal como un fuerte predictor de la capacidad productiva, reproductiva y del bienestar animal Roche et al. [2009].

Por lo tanto, el BCS es una herramienta fundamental en la gestión del ganado lechero, ya que permite estimar la movilización de reservas energéticas en grasa y músculo, siendo crucial para asegurar el bienestar animal y la eficiencia productiva. Según Yukun et al. [2019], el BCS es ampliamente utilizado para monitorear la ingesta de alimentos y el estado de salud del ganado, además de optimizar la gestión de la curva de lactancia. Sin embargo, la evaluación manual tradicional del BCS, aunque útil, es subjetiva y propensa a errores, dado que debe tenerse en cuenta la variabilidad entre observadores Morin et al. [2017].

Por otra parte, la mejora de la alimentación del ganado es esencial para maximizar la producción de leche, y en este contexto, la precisión en la evaluación del BCS se vuelve aún más crítica. Çevik [2020] destacan la importancia del BCS como el indicador principal de una alimentación adecuada en el ganado lechero, y señalan que agrupar a los animales según su puntuación de BCS permite una gestión más eficiente de la alimentación.

1.3 Motivación

A pesar del valor indiscutido del BCS, existe una subutilización de este valioso indicador en los sistemas comerciales por múltiples causas, entre las que se encuentran la no disponibilidad regular del/la experto/a en los movimientos de hacienda, superposición de actividades que relega su medición regular, falta local de especialistas entre otros De Hagen et al. [2010], Maresca et al. [2008], Selk et al. [1988]. Por este motivo, la principal motivación de este proyecto es la de desarrollar un prototipo de ambiente Dew con aplicación en el sector de producción tambero. La razón por la que se elige este dominio es porque se cuenta con avances obtenidos en el marco de una tesis doctoral sobre un modelo que aplica aprendizaje profundo para clasificación de ganado bovino basado en

el indicador de condición corporal. La idea es realizar un desarrollo que permita agilizar el etiquetado de imágenes –aumento del conjunto de datos de entrenamiento– que se realiza con una cámara de profundidad. También se busca realizar una clasificación en tiempo real in situ, es decir, a medida que los animales pasan por lo que en el campo se conoce con el nombre de manga donde se realizan diversas prácticas veterinarias. A partir del prototipo generado y planteando la tarea de clasificación a partir de imágenes como un cómputo en el que intervienen varios dispositivos de usuario, también se busca validar la performance de heurísticas de planificación de tareas estudiadas mediante simulación.

1.3.1 Escasez de prototipos

Si bien existe abundante investigación sobre algoritmos e inteligencia artificial aplicados en granjas Bao and Xie [2022], este artículo destaca que persiste la necesidad de desarrollar aplicaciones sistemáticas que integren dispositivos de recolección de datos, procesamiento y algoritmos inteligentes. Según estos autores, esto es especialmente relevante en el contexto de la ganadería inteligente, donde se requieren sistemas de bajo costo y modelos de IA eficientes. Sin embargo desafíos como la precisión de los sensores y el costo de los dispositivos, continúan siendo un obstáculo que debe superarse para lograr una implementación efectiva.

Además, los estudios sobre machine learning y reconocimiento de patrones han mostrado avances en áreas como la detección de enfermedades y el monitoreo del comportamiento animal. Sin embargo, como se observa en los artículos de Kumar et al. [2018] y Riekert et al. [2020], muchos de estos estudios se centran en marcos teóricos o modelos de detección sin una implementación práctica clara. Por ejemplo, el primero presenta un modelo de identificación de vacas mediante deep learning, pero no aborda cómo se implementará en la práctica.

En el ámbito del reconocimiento de patrones y procesamiento de imágenes, se han desarrollado diversos modelos teóricos sin implementación efectiva que pueden procesar y analizar información proveniente de imágenes, videos y sonidos de manera similar a la inteligencia cerebral. Estos modelos permiten describir e identificar comportamientos individuales, evaluar la calidad de la carne y medir el rendimiento en el crecimiento animal. Por ejemplo, Masferrer et al. [2018] propone un método de clasificación automática, combinados con datos intrínsecos de los cerdos, para simular un sistema de clasificación manual. Del mismo modo, Masferrer et al. [2018] introducen un algoritmo inteligente para el monitoreo del comportamiento alimentario mediante el reconocimiento de patrones y aprendizaje automático.

En el campo de las redes neuronales artificiales (ANN), los desarrollos recientes se han

enfocado principalmente en la creación de modelos y algoritmos dirigidos a la detección de enfermedades animales, la estimación del rendimiento de crecimiento y el monitoreo y control de las condiciones ambientales. Por ejemplo, Nasirahmadi et al. [2019] desarrollaron un algoritmo para monitorear automáticamente la postura de acostado lateral y esternal de los cerdos, proporcionando información crucial sobre su salud y bienestar.

Aunque todos estos modelos y algoritmos representan avances significativos en teoría, su implementación práctica en entornos reales aún es limitada. Esto subraya la necesidad de traducir estas innovaciones en soluciones tangibles que puedan ser aplicadas efectivamente en la ganadería, llevando los desarrollos teóricos al uso práctico en la producción animal.

1.4 Propuesta

La propuesta consiste en desarrollar un prototipo de ambiente de computación Dew compuesto de un componente servidor y una aplicación móvil diseñada para predecir el BCS en vacas lecheras, combinando tecnologías de inteligencia artificial, aprendizaje automático y computación en el borde. Este prototipo no sólo servirá para predecir el BCS utilizando un modelo de red neuronal previamente entrenado para vacas lecheras de raza Holstein-Friesian, sino que también permitirá almacenar la información obtenida durante las evaluaciones realizadas por expertos, dando la posibilidad de reentrenamiento continuo del modelo.

1.4.1 Objetivo

El objetivo general de este proyecto es el de desarrollar un prototipo de ambiente de computación Dew que aproveche capacidad de cómputo presente en la cercanía de un usuario para ejecutar tareas de clasificación y etiquetado in-situ. Desde el punto de vista práctico, la capacidad de cómputo estará representada por dispositivos de bajo costo tipo SBC (Single Board Computers) y/o dispositivos móviles (smartphones) que podrán asumirse ya presentes en el contexto de utilización (tambo lechero) o en su defecto factibles de ser desplegados con mínimos requerimientos para llevar a cabo tareas de clasificación de ganado en tiempo real. Las tareas de clasificación propiamente dichas, emplearán un modelo tensorflow previamente desarrollado en el marco de un trabajo publicado en una revista científica de alto impacto en el área de las tecnologías aplicadas al agro Alvarez et al. [2018]. El prototipo a desarrollar tiene múltiples propósitos que pueden resumirse en:

- 1- Contribuir a mejorar el modelo tensorflow a partir de un reentrenamiento que se será

posible gracias a la agilización del proceso de etiquetado de imágenes en las que interviene un profesional veterinario experto en el dominio.

2- Permitir que conocimiento experto en el dominio y encapsulado en una red de aprendizaje profundo pueda ser utilizado para automatizar la clasificación de ganado empleando dispositivos de usuario como plataforma de ejecución.

3- Permitir la validación de resultados de estrategias de planificación de tareas en grupos de dispositivos móviles estudiados con anterioridad en el grupo de trabajo y empleando simulación. De este objetivo general se desprenden los siguientes objetivos específicos:

- Diseño y desarrollo de una app móvil Android Evaluador que oficia de cliente y permite al profesional veterinario experto en el dominio etiquetar imágenes de ganado vacuno tomadas con una cámara de profundidad en tiempo real en el contexto de labores realizados en una manga, sin requerir de conexión a Internet.
- Diseño y desarrollo de una app móvil Android Visualizador que permite a un usuario no experto en el dominio conocer la condición corporal del ganado vacuno a medida que se obtienen imágenes de este en tiempo real y en el contexto de labores realizadas en una manga, sin requerir de conexión a Internet.
- Diseño y desarrollo de un componente servidor encargado de la gestión de tareas que son el etiquetado y clasificación automática diferenciando la app cliente de la cual provenga una petición.

Para los objetivos que se relacionan con el desarrollo móvil se adoptará como tecnología el framework Flutter por varias razones entre las que se encuentran la amplia disponibilidad de librerías y documentación, la posibilidad de generar aplicaciones multiplataforma -aunque el desarrollo quedará instanciado para la plataforma Android- y la experiencia previa en el uso del framework por parte de los directores del proyecto.

1.4.2 Contexto

El proyecto se enmarca en la aplicación de Tecnologías de la Información y la Comunicación (TICs) en el sector agropecuario, abordando la necesidad de evaluar con precisión la nutrición del rodeo lechero a través del BCS. Este proceso se realiza tradicionalmente en un lugar llamado "manga", donde cada vaca es inspeccionada visualmente por un profesional veterinario, denominado "Calificador", quien asigna un score basado en su experiencia.

1.4.3 Desafíos actuales

Uno de los principales desafíos es la escasez de calificadores expertos, lo que a menudo lleva a que las evaluaciones no se realicen o, cuando se llevan a cabo, se tornen propensas a errores debido a la alta carga de trabajo, especialmente en rodeos grandes. Además, la precisión de la evaluación puede variar según el estado del calificador, lo que introduce un margen de error adicional.

1.4.4 Solución propuesta

La aplicación móvil abordará estos desafíos mediante las siguientes funcionalidades:

- **Predicción del BCS mediante IA:** Utilizando un modelo de red neuronal entrenado con imágenes de vacas, la aplicación podrá clasificar automáticamente el BCS de cada animal con un score similar al que otorgaría un calificador humano. Este modelo ya ha sido desarrollado y entrenado en trabajos previos para vacas de , pero requiere un proceso continuo de reentrenamiento para mejorar su precisión y adaptabilidad.
- **Reentrenamiento automático del modelo:** La aplicación permitirá almacenar las calificaciones manuales realizadas por expertos, creando una base de datos de referencia que se utilizará para reentrenar el modelo de red neuronal. De este modo, cada nueva evaluación contribuirá a mejorar la precisión del algoritmo, permitiendo su adaptación a distintas condiciones y características del ganado.
- **Facilitación de uso por veterinarios:** La herramienta será accesible y fácil de usar por cualquier veterinario, incluso aquellos que no sean calificadores expertos. Esto no solo democratizará el uso de la tecnología, sino que también garantizará que las evaluaciones del BCS puedan realizarse con mayor frecuencia y precisión, sin depender exclusivamente de la disponibilidad de un calificador.

Resultados esperados

- **Automatización y precisión:** Al automatizar la predicción del BCS, se reducirá la dependencia de calificadores humanos y se minimizarán los errores derivados del cansancio o la subjetividad.
- **Mejora continua:** La posibilidad de reentrenar el modelo con nuevas evaluaciones permitirá una mejora continua del algoritmo, adaptándose mejor a las variaciones individuales del ganado y las condiciones específicas de cada rodeo.

- Accesibilidad y eficiencia: Veterinarios no especializados podrán realizar evaluaciones precisas del BCS, optimizando el tiempo y los recursos invertidos en el manejo nutricional del rodeo. Este prototipo no sólo permitirá optimizar la gestión nutricional en el sector agropecuario, sino que también contribuirá a la evolución de las prácticas tradicionales hacia un enfoque más tecnológico y eficiente.

Trabajos relacionados

2.1 Importancia y avances de la IA para calcular BCS

El procesamiento de imágenes es un paso clave para extraer características relevantes para la evaluación del BCS. Tradicionalmente, la extracción de características visuales se ha realizado mediante métodos manuales, en combinación con técnicas estadísticas como el Análisis de Componentes Principales (PCA) Kurita [2019]. El PCA es un método que transforma un conjunto de características originales en un nuevo conjunto de variables no correlacionadas llamadas componentes principales, reduciendo así la dimensionalidad de los datos. Sin embargo, el uso del PCA en este contexto, al igual que otros enfoques lineales, tiene limitaciones importantes. Al depender de un número limitado de puntos de características y muestras, el PCA puede perder información crucial en escenarios más complejos, lo que resulta en modelos predictivos menos eficientes y precisos Fischer et al. [2015]. Para abordar estos desafíos, el aprendizaje profundo basado en redes neuronales artificiales ha demostrado ser una herramienta poderosa para la modelización predictiva; las técnicas populares utilizadas para analizar imágenes incluyen las redes neuronales convolucionales (CNN). La estructura de CNN imita una red neuronal biológica y se aplica fácilmente a la identificación de imágenes visuales Singh et al. [2016]. En la agricultura ganadera, las CNN se han aplicado ampliamente a la clasificación e identificación de imágenes en áreas como el reconocimiento de comportamientos animales, la monitorización del estado de salud y la identificación de individuos Kamilaris and Prenafeta-Boldú [2018]. En este sentido, las CNN también han sido empleadas para la estimación del BCS de vacas a partir de imágenes de profundidad, como se demuestra en Rodríguez Alvarez et al. [2018]. Este trabajo destaca el uso de imágenes tridimensionales y técnicas de aprendizaje profundo para lograr evaluaciones precisas del BCS, mejorando así el proceso de monitoreo del bienestar animal.

Además de los avances en inteligencia artificial para la evaluación del BCS, es crucial considerar el papel de las tecnologías de soporte que facilitan el procesamiento de datos en entornos distribuidos y con recursos limitados, como es el caso de Dew Computing, un paradigma que se presenta como una alternativa sustentable para la ejecución de aplicaciones IoT en áreas rurales y de conectividad limitada.

2.2 Importancia de dew computing

Dew Computing Skala et al. [2015] Rindos and Wang [2016] nace como un paradigma de computación posterior a Edge/Fog Computing que se presenta como una alternativa sustentable para soportar aplicaciones IoT. Puede operar acoplada o desacoplada de los servicios de ejecución que ofrece el Cloud Gusev and Wang [2018]. En el segundo caso, asociado a lo que puede ser una falta de conectividad, se explotan recursos presentes en el contexto local al usuario, también denominados “on premises resources” dentro de los cuales se encuentran dispositivos de usuario como smartphones o single board computers (SBC). Las capacidades de cómputo no despreciables que ofrecen hoy en día estos dispositivos posibilitan la ejecución de software recurso-intensivo. Existen ejemplos donde estos dispositivos consituyen el principal soporte de ejecución de software complejo en ámbitos profesionales Prego et al. [2018] Singh et al. [2017] Aquino et al. [2018]. Incluso cuando un único de estos dispositivo carezca de los recursos necesarios para cumplir con la ejecución de una tarea en el tiempos que se espera, aparecen trabajos en la literatura que plantean enfoques de ejecución colaborativos, donde una tarea se paraleliza y ejecuta en grupos de dispositivos Hirsch et al. [2018]. La eficiente utilización de un grupo de dispositivos en un contexto local plantea desafíos a nivel plataforma, tal como el estudio de componente de planificación de tareas, que es necesario seguir estudiando dada la heterogeneidad en términos de eficiencia energética y prestaciones que puede encontrarse de los dispositivos de usuario Hirsch et al. [2017] Hong and Varghese [2019]. Es una práctica común y aceptada en el estudio de sistemas distribuidos la experimentación mediante simulación Hirsch et al. [2018] Apolónia et al. [2017] Hirsch et al. [2020]. Esto es dada la inherente complejidad de configuración, costos monetarios y tiempo que conlleva estudiar estrategias de planificación en sistemas distribuidos montados sobre ambientes de ejecución reales. En relación a esto, DewSim Hirsch et al. [2020] permite modelar clusters de dispositivos móviles y evaluar estrategias de planificación de tareas teniendo en cuenta aspectos que tienen que ver con el consumo de energía de las baterías y uso de CPU de los dispositivos. Si bien la simulación resulta de suma utilidad para estudiar de forma exploratoria nuevas estrategias de planificación de tareas en ambientes Dew, es relevante contar con datos extraídos de la ejecución de aplicaciones Dew reales, ya sea para validar los resultados obtenidos mediante simulación como

para retroalimentar el modelo de entidades que forman parte de DewSim.

2.3 Comparaciones

En el campo de la gestión ganadera, varios estudios recientes han abordado la automatización y optimización de procesos clave en áreas como la alimentación, bienestar animal, salud y reproducción del ganado.

- En Çevik [2020] se usa BCS para agrupar y mejorar las tareas de cuidado y alimentación de los animales en determinados momentos. El objetivo es proporcionar una herramienta de fácil acceso a los productores de lácteos con la ayuda del software móvil diseñado. Se desarrolló un software para estimar los valores de BCS utilizando imágenes en tiempo real en dispositivos móviles Android llevándose a cabo con la ayuda de arquitecturas CNN que fueron entrenadas con imágenes tomadas por un software y evaluadas por un experto de manera offline. La red entrenada se transfirió al software móvil para utilizar el modelo entrenado y realizar predicciones en tiempo real. El software posee el modelo entrenado para realizar la toma de la foto y predecir el valor de BCS. De esta manera, no necesita acceso a cloud.
- Alonso et al. [2020]: Desarrollo de una plataforma diseñada para monitorear, rastrear y optimizar las tareas de gestión de explotaciones mixtas de cultivo y ganadería. La tecnología integra visualización de datos, un sistema de alertas, un mapa interactivo de dispositivos IoT y una interfaz para configurar sensores. Además, registra y almacena datos biométricos del ganado lechero, mostrando su actividad y un historial de fiebre, combinando temperatura, ritmo respiratorio y frecuencia cardíaca.
- En Piedade et al. se propone una red de sensores inalámbricos (WSN) con nodos LoRa, MongoDB y comunicaciones de largo alcance para monitorear la salud del ganado en hatos lecheros. Los nodos LoRa recopilan datos y los transmiten a través de un LoRa Gateway, validando la viabilidad del sistema. Este enfoque permite generar alertas sobre la salud del ganado, detectar estro y prevenir robos. El sistema convierte los datos recibidos por el gateway a JSON y los almacena en MongoDB. Luego, los datos procesados se publican a través de un broker MQTT, permitiendo que aplicaciones móviles accedan y presenten los resultados en un dashboard externo.
- En Yang et al. [2017] se desarrolló un sistema de monitoreo usando cámaras infrarrojas para registrar imágenes nocturnas de vacas lecheras. El procesamiento de imágenes identifica comportamientos de celo, facilitando que los propietarios tomen

decisiones sobre la inseminación artificial. Utilizando análisis de energía dinámica de imágenes y procesamiento de imágenes binarias, pueden identificar cambios en la longitud de las vacas durante el comportamiento de montaje específico del estro. Los eventos que se ajusten a nuestra regla se grabarán como videos y se guardarán en la computadora. El prototipo se realizó con una sola cámara pero sugiere utilizar una cámara nocturna de ojo de pez a futuro para registrar actividades en un área más amplia de la granja lechera, superando la limitación de cobertura de una sola cámara. Esto evitaría la necesidad de combinar imágenes de múltiples cámaras y supera los problemas de los sensores de contacto directo utilizados en otras propuestas, que pueden ser perjudiciales para las vacas. Los eventos que se ajusten a la regla establecida se grabarán como videos y se guardarán en la computadora. Estos eventos serán evaluados más adelante por los propietarios. Por lo tanto, no es necesario acceso a internet.

Estos trabajos han explorado diversas tecnologías para mejorar la captura de datos, el análisis y la toma de decisiones, utilizando aplicaciones móviles, inteligencia artificial y diferentes contextos y modos de ejecución. A continuación, se presenta una comparación que sintetiza estos aspectos en los principales trabajos relacionados, destacando no solo el uso de inteligencia artificial para la evaluación de la Condición Corporal (BCS), sino también su aplicación en otras áreas críticas de la ganadería, así como el uso de distintos dispositivos, técnicas de sensado y contextos de ejecución.

Trabajo	Objetivos de monitoreo	Rol de la app móvil
Çevik [2020]	Alimentación, Bienestar animal	Toma de imágenes y soporte para inferencia d
Piedade et al.	Salud Animal, Reproducción	Visualización de resultados
Alonso et al. [2020]	Bienestar animal, Alimentación	Visualización de resultados
Yang et al. [2017]	Reproducción	N/A

2.3.1 Limitaciones halladas en trabajos relacionados

Si bien los trabajos revisados ofrecen soluciones tecnológicas interesantes para el sector agro-ganadero, presentan algunas limitaciones importantes. En primer lugar, no se observa un sistema que proporcione asistencia en tiempo real para el apartamiento o agrupamiento de vacas utilizando el cómputo del BCS y cámaras estratégicamente colocadas. La dependencia de la captura manual de imágenes en Çevik [2020] por parte del usuario introduce márgenes de error que pueden afectar la precisión de las predicciones, además de aumentar la carga de trabajo.

En segundo lugar, aunque algunos trabajos como Çevik [2020] calculan el BCS en tiempo real sin depender de la nube, otros, como Alonso et al. [2020], utilizan técnicas de in-

teligencia artificial que requieren procesamiento en la nube para obtener resultados avanzados. Aunque Alonso et al. [2020] almacena estadísticas y datos brutos en el edge, el procesamiento avanzado de IA y la visualización de resultados dependen de la nube. Esto puede ser una limitación en entornos rurales con conectividad inestable, ya que las funcionalidades más complejas del sistema no estarán disponibles sin conexión a internet.

En cuanto al historial del BCS, ninguno de los trabajos revisados ofrece un sistema que almacene y mantenga registros continuos de las predicciones de BCS, ni en el edge ni en la nube. Aunque Alonso et al. [2020] mantiene algunas estadísticas en el edge, los cálculos y resultados avanzados de IA solo están disponibles a través de la nube, lo que restringe el análisis profundo en el edge, dónde solo se puede acceder a datos no procesados.

Además, tanto en el trabajo de Piedade et al. como en el de Yang et al. [2017], la interpretación de los datos y el análisis de las imágenes capturadas dependen totalmente del usuario, ya que no se emplean técnicas de inteligencia artificial para automatizar estos procesos. Esto introduce una mayor carga de trabajo y puede ralentizar la toma de decisiones, aumentando el riesgo de interpretaciones subjetivas y potencialmente erróneas. Asimismo, en el caso de Piedade et al., el uso de collares en las vacas añade costos adicionales y posibles inconvenientes para los animales.

Por último, no se ha abordado en los trabajos revisados la posibilidad de mejorar de forma continua los modelos predictivos del BCS. La falta de un mecanismo que permita la retroalimentación del modelo mediante el etiquetado de imágenes y la actualización del sistema de predicción limita la personalización y ajuste del sistema a las características particulares de cada rodeo, algo fundamental para mejorar la precisión y eficiencia de las soluciones en el largo plazo.

A pesar de que existen propuestas que utilizan computación en el edge, aplicaciones móviles, cálculo del BCS, visualización de datos o automatización, no se observa ninguna que reúna todas estas características de forma integrada. Esta falta de integración limita la adaptabilidad de las soluciones a diferentes entornos y necesidades, lo que resalta la relevancia a la propuesta de este trabajo, que busca ofrecer una solución completa y robusta para abordar estas limitaciones en el sector agro-ganadero.

2.3.2 Mejoras de mi propuesta

El objetivo general de este proyecto es el de desarrollar un prototipo de ambiente de computación Dew que aproveche capacidad de cómputo presente en la cercanía de un usuario para ejecutar tareas de clasificación y etiquetado. Desde el punto de vista práctico, la capacidad de cómputo estará representada por dispositivos de bajo costo tipo SBC (Single Board Computers) y/o dispositivos móviles (smartphones) que podrán asumirse

ya presentes en el contexto de utilización (tambo lechero) o en su defecto factibles de ser desplegados con mínimos requerimientos para llevar a cabo tareas de clasificación de ganado en tiempo real. Las tareas de clasificación propiamente dichas, emplearán un modelo tensorflow previamente desarrollado en el marco de un trabajo publicado en una revista internacional de alto impacto en el área de tecnologías aplicadas al agro Alvarez et al. [2018]. El prototipo a desarrollar tiene múltiples propósitos que pueden resumirse en:

1. Contribuir a mejorar el modelo tensorflow a partir de un reentrenamiento que se será posible gracias a la agilización del proceso de etiquetado de imágenes en las que interviene un profesional veterinario experto en el dominio.
2. Permitir que conocimiento experto en el dominio y encapsulado en una red de aprendizaje profundo pueda ser utilizado para automatizar la clasificación de ganado empleando dispositivos de usuario como plataforma de ejecución.
3. Permitir la validación de resultados de estrategias de planificación de tareas en grupos de dispositivos móviles estudiados con anterioridad en el grupo de trabajo y empleando simulación.

De este objetivo general se desprenden los siguientes objetivos específicos:

- Diseño y desarrollo de una app móvil Android Evaluador que oficia de cliente y permite al profesional veterinario experto en el dominio etiquetar imágenes de ganado vacuno tomadas con una cámara de profundidad en tiempo real en el contexto de labores realizados en una manga, sin requerir de conexión a Internet.
- Diseño y desarrollo de una app móvil Android Visualizador que permite a un usuario no experto en el dominio conocer la condición corporal del ganado vacuno a medida que se obtienen imágenes de este en tiempo real y en el contexto de labores realizadas en una manga, sin requerir de conexión a Internet.
- Diseño y desarrollo de un componente servidor encargado de la gestión de tareas que pueden ser de etiquetado o clasificación automática diferenciando la app cliente de la cual provenga una petición.
- Diseño y desarrollo de un módulo de generación de reportes que permitirá tanto a observadores como a calificadores visualizar reportes gráficos del BCS calculada por el algoritmo de predicción.

Requerimientos

El sistema debe ofrecer una solución para automatizar el cálculo del índice BCS del ganado, a través de la aplicación observador y mejorar dicho índice con la ayuda de la aplicación calificador. . El sistema integra tecnologías de IoT, deep learning y una infraestructura de computación Dew. A continuación se detallan los requerimientos claves.

3.1 Requerimientos funcionales

- **Calidad de Imágenes y Datos de Entrenamiento:** La aplicación debe ser capaz de capturar y procesar imágenes de alta calidad de vacas de diferentes razas lecheras, más allá de la raza Holstein. Estas imágenes deben ser etiquetadas con valores de BSC proporcionados por expertos en el lugar, quienes puntuarán de manera independiente para minimizar la subjetividad. Estos datos constituyen el ground truth necesario para entrenar, rediseñar y validar los modelos de predicción del BSC.
- **Capacidad Predictiva y Almacenamiento de Datos:** Una vez que los modelos de predicción del BSC estén operativos, la aplicación debe alojar estos algoritmos en dispositivos computacionales que se integren al aparejo móvil. Estos dispositivos deben ser capaces de ejecutar los algoritmos en tiempo real, utilizando computación Dew para reducir la dependencia de la conectividad a internet. El servidor central debe almacenar datos de los usuarios, sesiones de calificación, BSC asignadas por expertos, y resultados de los algoritmos predictivos, asegurando la disponibilidad de esta información para la generación de reportes.
- **Aplicación Móvil y Perfiles de Usuario:** La aplicación móvil debe soportar dos perfiles de usuario: calificadores y observadores. Los calificadores, generalmente ex-

pertos, deben poder realizar la calificación del BSC de cada vaca y visualizar reportes detallados. Los observadores, en cambio, tendrán acceso al cálculo automatizado de BCS -resultado de una inferencia- y a la visualización de reportes, los cuales se actualizan en tiempo real según los últimos datos procesados. Además, los dispositivos utilizados por los observadores podrán participar de la ejecución del algoritmo predictivo, informando tanto a otros observadores como al servidor central para el almacenamiento y uso de estos datos en reportes.

- **Interfaz de Comunicación y Reportes:** La aplicación debe incluir un módulo para la generación de reportes en formato gráfico, como diagramas de torta, que permita a los usuarios visualizar la distribución del BSC en diferentes rangos. Estos reportes deben ser accesibles para diferentes sesiones de calificación (actual, última finalizada, y anteriores) y se actualizarán en tiempo real. La interfaz de usuario debe ser intuitiva, permitiendo la fácil navegación entre las diferentes opciones de visualización.
- **Interfaz de captura de datos:** El prototipo incluirá una interfaz de entrada diseñada para recibir las imágenes capturadas de las vacas y su correspondiente identificación. Las imágenes serán tomadas automáticamente por la cámara ubicada en la manga mientras las vacas pasan debajo de esta. Simultáneamente, la identificación de cada vaca se obtendrá mediante un sistema RFID, asegurando que cada imagen esté correctamente asociada al animal correspondiente. Esta interfaz permitirá un flujo de datos continuo y preciso, facilitando la posterior clasificación y análisis del BSC en tiempo real.
- **Autorización:** definirá los permisos de cada usuario según su rol dentro del sistema, diferenciando entre calificadores y observadores.
 - **Calificadores:** Pueden iniciar nuevas sesiones de calificación, etiquetar imágenes, y acceder a los reportes generados por las sesiones que han realizado.
 - **Observadores:** Pueden visualizar los reportes generados, consultar el historial de sesiones, y acceder tanto a la predicción en tiempo real del BCS como al historial asociado de cada vaca. Sin embargo, no tienen permisos para realizar calificaciones.

3.2 Casos de uso

3.2.1 Login

La interfaz de usuario permite ingresar el nombre de usuario para iniciar sesión sin necesidad de una contraseña. Durante el proceso de registro, los usuarios tienen la op-

ción de seleccionar su rol, ya sea como calificador u observador.

El flujo de creación de usuario comienza desde la página de usuario en la aplicación móvil. Los usuarios crean una nueva cuenta ingresando su nombre y seleccionando su rol. Este proceso garantiza que el nombre de usuario sea único y que el usuario sea identificado correctamente como calificador u observador. Tras la creación de la cuenta, los usuarios inician sesión ingresando simplemente su nombre, lo que les permite acceder a las funcionalidades específicas de su rol.

El sistema clasifica a los usuarios según su rol, lo que determina las funciones y vistas a las que tienen acceso. Los calificadores pueden realizar nuevas calificaciones y etiquetar imágenes, mientras que los observadores tienen acceso a la visualización de reportes y predicciones en tiempo real, sin la posibilidad de modificar datos. Esta diferenciación asegura que cada usuario interactúe con el sistema de acuerdo con sus funciones específicas, proporcionando una experiencia personalizada.

La sesión de usuario es fundamental para asociar las calificaciones realizadas a la cuenta del usuario. Esto permite al sistema rastrear y organizar las calificaciones, así como gestionar el historial de reportes y predicciones, mostrando sólo la información relevante para cada usuario.

3.2.2 Sesión de calificación

Las sesiones de calificación son esenciales para gestionar y registrar datos que forman parte del ground truth para el entrenamiento de un modelo de aprendizaje profundo. Durante una sesión de calificación, un experto, conocido como calificador, evalúa de a una por vez, un grupo de vacas usando la aplicación móvil. En estas sesiones, uno o más calificadores participan en la evaluación de cada vaca, y sus calificaciones se almacenan para su uso posterior, como en el entrenamiento de modelos de predicción.

La gestión de las sesiones de calificación es clave para garantizar que las evaluaciones se registren y organicen adecuadamente. Un calificador inicia una sesión en una locación (campo) específica, y se le asocia automáticamente a esa sesión. No se permite la existencia de más de una sesión activa en la misma locación, aunque es posible que varios calificadores participen en una misma sesión.

Las sesiones de calificación se almacenan con un identificador único y registran las fechas de inicio y finalización, lo que es crucial para generar reportes detallados sobre las evaluaciones realizadas.

Los casos de uso incluyen:

- **Inicio de Sesión de Calificación:** Un calificador inicia una sesión en una locación específica y se asocia automáticamente a esta sesión.

- Finalización de Sesión de Calificación: Un calificador finaliza una sesión previamente iniciada, marcando el cierre de la sesión en el sistema.
- Unirse a una Sesión de Calificación: Un calificador puede unirse a una sesión activa en su locación si no ha iniciado su propia sesión. Aunque la aplicación móvil actual no permite unirse a sesiones activas, el sistema está diseñado para manejar esta funcionalidad, permitiendo su extensión futura.
- Locación de la Sesión de Calificación: La administración de locaciones no está implementada en la aplicación móvil, aunque el sistema soporta estas opciones para facilitar futuras mejoras.

3.2.3 Sistema de notificación de imágenes

El sistema recibe imágenes de vacas y procesa la información asociada para la calificación y visualización del BCS. El flujo comienza cuando las imágenes de cada vaca, junto con su metadata son transmitidas al servidor. El servidor, que cuenta con una interfaz de recepción de datos, es responsable de recibir y procesar esta información.

- Sistema de Envío: Este componente es responsable de transmitir las imágenes de las vacas al servidor, junto con la identificación de la vaca, posición en la caravana y conjunto de imágenes. El sistema de envío incluye un sistema RFID que captura automáticamente la identificación de la vaca cuando pasa por la manga, sincronizando esta información con la captura de la imagen. De esta manera, se asegura que cada imagen esté correctamente asociada a la vaca correspondiente. Cabe destacar que el sistema de captura de imágenes, queda fuera del alcance de este proyecto.
- Recepción y Almacenamiento de Imágenes: Las imágenes y su meta-data asociada se reciben en el servidor donde son almacenadas. Esta interfaz permitirá un flujo de datos continuo y preciso, facilitando la posterior clasificación y análisis del BSC en tiempo real.
- Gestor de mensajes de imágenes: Una vez que las imágenes y su meta-data han sido almacenadas, se genera una notificación interna entre el servidor y la aplicación móvil que permite un flujo continuo de imágenes hacia los calificadores y observadores. Los calificadores pueden acceder a las imágenes solicitando la siguiente disponible dentro de su sesión activa, mientras que los observadores reciben automáticamente las imágenes en tiempo real, acompañadas de los metadatos correspondientes.

3.2.4 Calificadores

Los calificadores son expertos especializados en la evaluación del BCS, ya sea a partir de imágenes recibidas o mediante la observación directa de las vacas en la manga. Con base en su experiencia y conocimiento, asignan una puntuación de BCS a cada vaca evaluada, la cual es almacenada. Al ingresar el puntaje, este se asocia tanto a la vaca como a la sesión de calificación correspondiente, lo que garantiza una gestión de datos organizada y trazable. Esta información resulta fundamental para entrenar y mejorar continuamente los modelos predictivos de BCS en futuras iteraciones del sistema. Además de asignar las puntuaciones, los calificadores tienen la capacidad de visualizar reportes.

3.2.5 Observadores

Los usuarios con rol observador pueden visualizar la predicción del BCS y también tendrán acceso a diversos reportes, por ejemplo, evolución en el tiempo del BCS de un animal e historial de BCS de un rodeo. Los dispositivos de usuarios observadores por defecto participan de la ejecución del algoritmo de predicción del BCS aportando recursos computacionales, acción que no afecta la experiencia de usuario con la app y cuyo resultado se distribuirá automáticamente por el sistema entre otros observadores presentes.

3.2.6 Reportes

El sistema de reportes proporciona a calificadores y observadores acceso a la visualización de datos sobre las evaluaciones del BCS predichas por el algoritmo de predicción. Estos reportes se presentan en diagramas de torta que agrupan las vacas dentro de los siguientes rangos de puntaje:

- 0 a 0.99
- 1 a 1.99
- 2 a 2.99
- 3 a 3.99
- 4 a 5
- Sin predicción

Los casos de uso incluyen:

- Visualización de Reportes en Sesiones Actuales:

- Los observadores pueden acceder a reportes que se actualizan automáticamente durante la sesión de calificación en curso. Los valores de BCS generados por el algoritmo se reflejan en los diagramas de torta en tiempo real, lo que permite un monitoreo continuo del estado de las vacas.
- Los calificadores tienen la opción de visualizar los reportes cuando lo consideren necesario. Sin embargo, dado que su función principal es la evaluación directa de las vacas, los diagramas se actualizan solo cuando el calificador decide consultar esta información, asegurando que accedan a los datos más recientes en ese momento.
- Acceso a Reportes de Sesiones Anteriores: Los usuarios pueden acceder a los reportes de sesiones de calificación terminadas, donde pueden consultar los puntajes BCS registrados durante esas sesiones.
- Historial BCS para Observadores: Los observadores, además de ver los reportes actuales, pueden acceder al historial de predicciones BCS de vacas en sesiones de calificación anteriores, lo que les permite tener una visión más amplia del progreso o cambios en la condición corporal de las vacas a lo largo del tiempo.

Diseño

El sistema permite el procesamiento en tiempo real de imágenes de vacas, facilitando tanto la observación como la calificación de su condición corporal. La interfaz de usuario comienza con una pantalla de inicio de sesión, donde los usuarios se autentican. Dependiendo del rol asignado (calificador u observador), el sistema presenta diferentes funcionalidades: los calificadores se enfocan primero en iniciar o finalizar una sesión de calificador y luego en evaluar el BCS de las vacas mediante un proceso de etiquetado manual, mientras que los observadores visualizan las imágenes en tiempo real y ejecutan el modelo predictivo de BCS de forma automática con un modelo pre-entrenado. El sistema utiliza un esquema distribuido, donde el procesamiento de las imágenes se gestiona a través de una cola de mensajes (JMS), permitiendo un flujo de imágenes capturadas en tiempo real de las vacas que están pasando por la manga. Estas imágenes se envían al servidor y se asocian a una vaca y a una locación específica. La cola de mensajes asegura el orden adecuado de las imágenes, mientras que el componente receptor almacena las imágenes en función de su metadata asociada. Además, el servidor gestiona las interacciones de calificadores y observadores, facilitando la creación de sesiones y el registro de calificaciones para los calificadores, así como la transmisión de datos de predicción para los observadores y, asimismo, provee reportes accesibles para ambos roles.

4.1 Login

El flujo de creación de usuario en la aplicación móvil se implementa mediante el envío de una solicitud POST al servidor. El módulo de creación de usuario del servidor procesa esta solicitud, generando el nuevo usuario en el sistema y asegurando que el nombre sea único a través de una validación.




Figure 4.1: Componentes del sistema

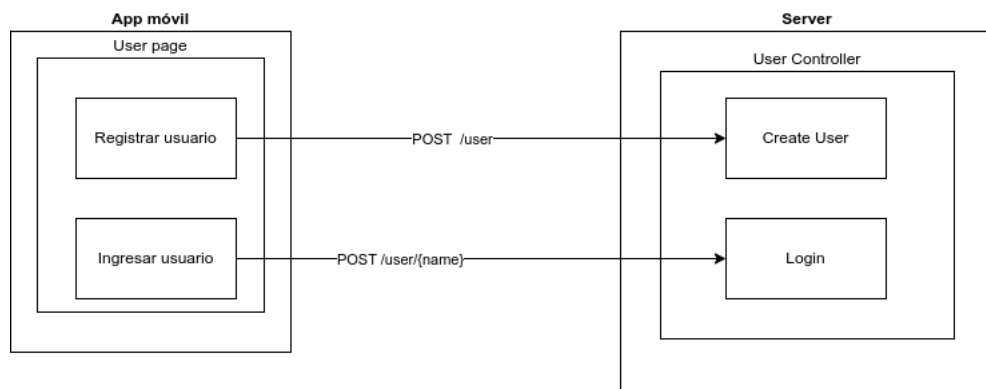


Figure 4.2: Diagrama de componentes - login

Para la autenticación, cuando un usuario ingresa su nombre en la aplicación, se envía una solicitud POST, la cual es manejada por el módulo de login del servidor. El sistema verifica la identidad del usuario únicamente a través de su nombre, sin necesidad de una contraseña. Una vez identificado, el sistema clasifica al usuario como calificador u observador, habilitando o restringiendo funciones según su rol.

Este diseño del módulo de login, junto con la funcionalidad de creación de usuarios y la validación de nombres únicos, se alinea con los objetivos del prototipo. Se prioriza la simplicidad y la funcionalidad básica, dejando de lado la implementación de medidas de seguridad avanzadas que podrían ser consideradas en versiones futuras.

4.2 Sesión de calificación

Cada sesión de calificación está vinculada a una locación específica, predefinida en los

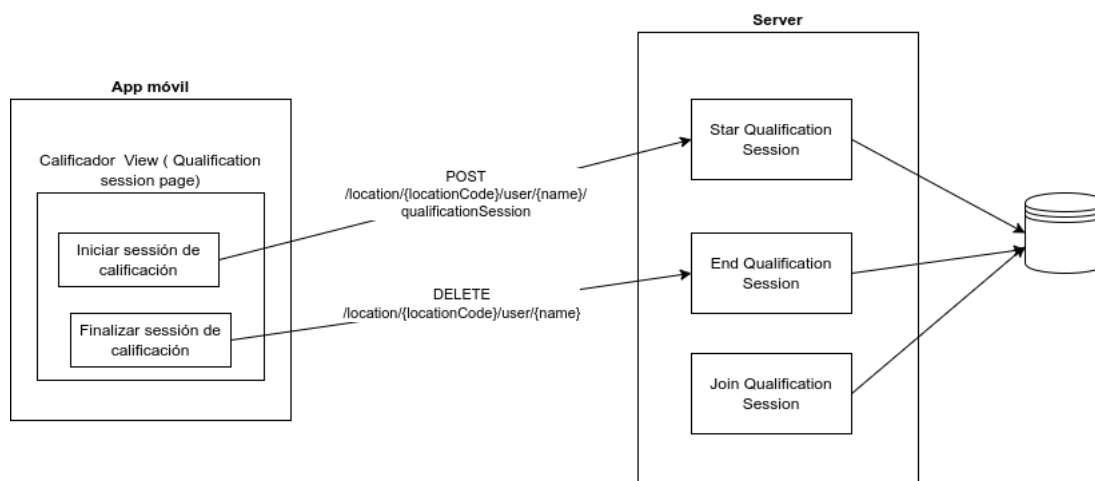


Figure 4.3: Diagrama de componentes - sesión de calificación

scripts de inicialización del sistema. Este prototipo establece una sesión de calificación por defecto para simplificar la operación, pero el diseño del servidor permite la posibilidad de múltiples sesiones simultáneas en distintas locaciones. Esto significa que diferentes calificadores pueden trabajar en paralelo, ya sea en diferentes locaciones o en la misma. El hecho de permitir sesiones en diferentes locaciones en paralelo, abre la posibilidad a que el componente servidor de servicio desde nodos a los que se accede mediante internet.

El servidor genera automáticamente un identificador único para cada sesión de calificación, junto con las marcas de fecha y hora de inicio y finalización al comenzar o concluir la sesión. Aunque la aplicación móvil actualmente está limitada a la gestión de la sesión por defecto, el sistema permite que varios calificadores trabajen simultáneamente en diferentes locaciones o en la misma locación, aunque esta funcionalidad no está completamente implementada en la aplicación móvil en esta etapa.

En su estado actual, solo el calificador tiene la capacidad de iniciar y finalizar una sesión, lo que implica que no puede haber una sesión sin la intervención del calificador. No obstante, es posible iniciar una sesión de calificación sin la presencia física de un calificador mediante la invocación directa de la misma llamada REST que este utilizaría para gestionar la sesión. Esto permite que el sistema mantenga sesiones de calificación sin requerir la intervención directa del calificador en todo momento. En el futuro, el sistema podría adaptarse para que los observadores también tengan la capacidad de iniciar y finalizar sesiones, lo que ofrecería mayor flexibilidad, permitiendo que tanto observadores como calificadores trabajen de manera independiente, sin depender necesariamente de la presencia del otro.

La base de datos registra cada sesión de calificación, lo que es esencial para el módulo de reportes que genera informes basados en estas sesiones. Los componentes claves in-

cluyen:

- **Inicio de Sesión de Calificación:** El servidor gestiona el inicio de las sesiones de calificación, garantizando que solo exista una sesión activa por locación. Además, se encarga de asociar a la nueva sesión todas las imágenes previamente almacenadas que aún no estén vinculadas a una sesión. De este modo, se asegura que ninguna imagen quede sin procesar si no hay una sesión de calificación activa en el momento de su recepción.
- **Finalización de Sesión de Calificación:** El servidor cierra la sesión, permitiendo el uso de datos en reportes.
- **Unirse a una Sesión de Calificación:** Aunque el servidor soporta esta funcionalidad, la aplicación móvil actual no permite que un calificador se una a una sesión iniciada por otro.
- **Locación de la Sesión de Calificación:** Actualmente, sólo permite iniciar o finalizar sesiones en la locación por defecto, pero es extensible para permitir más funcionalidades en futuras versiones.

4.3 Sistema de notificación de imágenes

El diseño del sistema para notificar las imágenes de las vacas se centra en varios componentes clave que interactúan para garantizar el procesamiento adecuado de las imágenes y su integración con el flujo de calificación y observación. A continuación, se detalla el proceso de recepción y almacenamiento de imágenes, la gestión de mensajes, y el rol específico de los calificadores y observadores en la transmisión y visualización de estos datos.

4.3.1 Recepción y Almacenamiento de Imágenes

El sistema cuenta con una interfaz REST que recibe las imágenes capturadas junto con la identificación de la vaca, la locación de la manga y la posición de la vaca. Este último dato corresponde al orden en el que se registran los eventos, es decir, la posición de la vaca en la caravana dentro del sistema de identificación. Este mecanismo asegura que las imágenes estén asociadas a la vaca correcta, la posición de esta dentro de la caravana a la locación específica desde donde se envían. La metadata relacionada (identificación de la vaca, locación, posición etc.) se almacena en la base de datos, mientras que las imágenes en sí se guardan en el sistema de archivos.

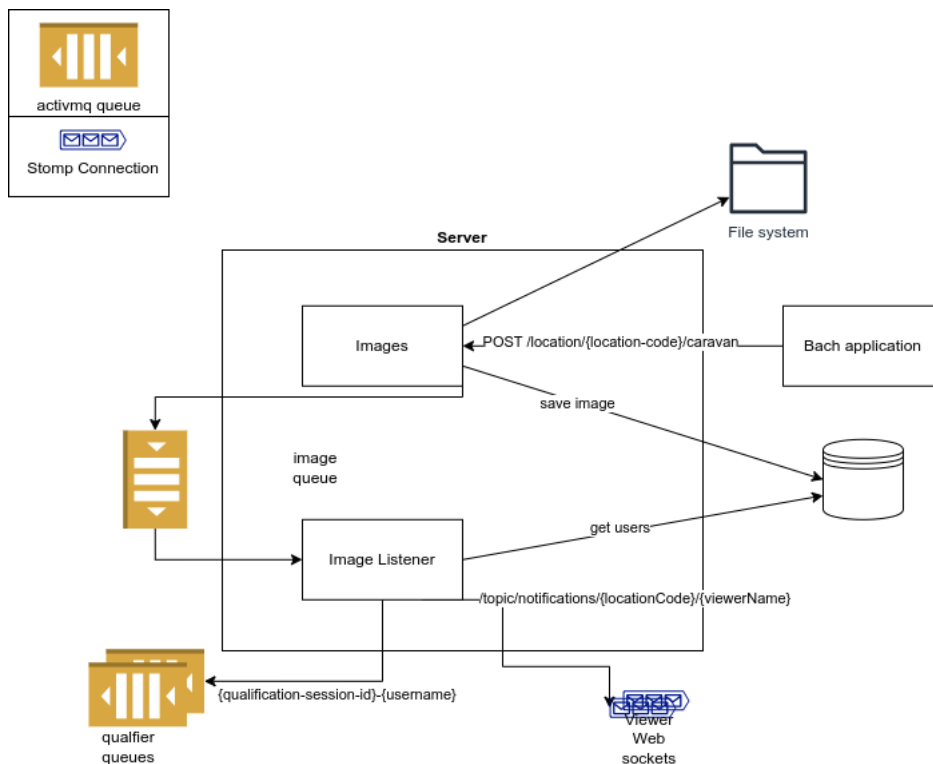


Figure 4.4: Diagrama de componentes - imágenes

Este proceso ocurre de manera independiente a la activación de una sesión de calificación, ya que las imágenes se almacenan de inmediato y se asocian a la sesión correspondiente cuando esta se inicia. Dado que no puede haber más de una sesión de calificación por locación y que las imágenes están asociadas tanto a una vaca como a una locación, es sencillo determinar qué imágenes deben ser utilizadas por los observadores para realizar la predicción de BCS.

Posteriormente, cada conjunto de imágenes genera un mensaje JMS (Java Message Service) que es enviado a una cola de procesamiento. Cada conjunto se asocia a un único animal, asegurando que la información enviada para su procesamiento corresponda exclusivamente a una vaca en particular.

4.3.2 Gestor de mensajes de imágenes

El Gestor de Mensajes de Imágenes distribuye los mensajes generados por la llegada de imágenes a los componentes correspondientes que incluyen tanto la gestión de las imágenes que serán calificadas por expertos como las que se visualizarán en tiempo real por los observadores. Este proceso se realiza mediante dos rutas principales:

- Mensajes a calificadores: El sistema verifica la locación de las imágenes para deter-

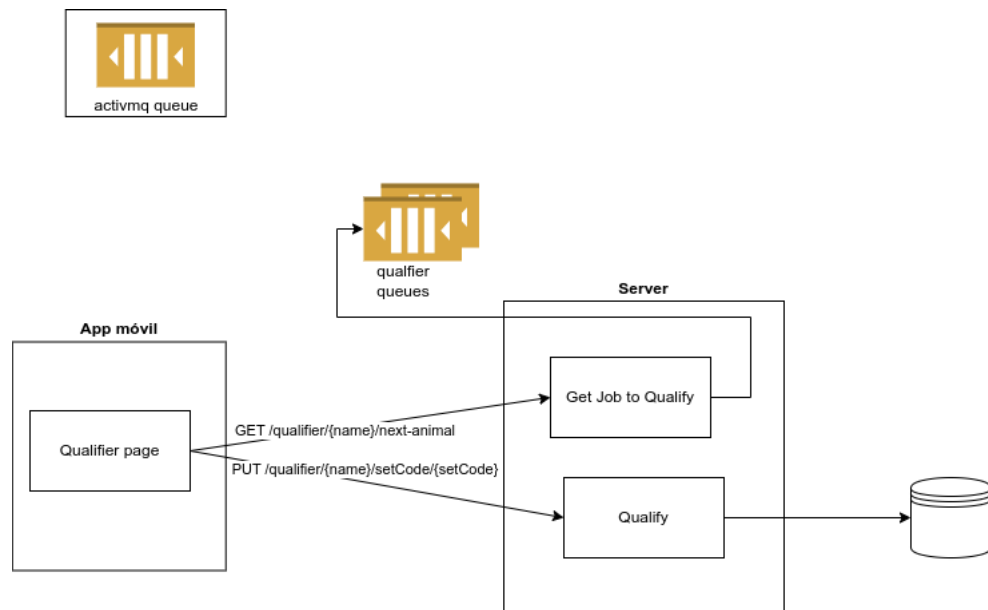


Figure 4.5: Diagrama de componentes: calificador

minar si hay una sesión de calificación activa. Si es así, los mensajes JMS se envían a las colas de los calificadores asociados a esa sesión, permitiendo que puedan realizar la evaluación. Es imprescindible que exista una sesión activa para que los calificadores accedan a las imágenes.

- Mensajes a observadores: Los observadores reciben las imágenes a través de una conexión websocket, independientemente de la existencia de una sesión de calificación. Las imágenes son transmitidas en tiempo real para que los observadores las visualicen.

Esta arquitectura asegura una distribución eficiente de las imágenes: los calificadores trabajan en sus respectivas sesiones y los observadores pueden ver las imágenes y ejecutar el algoritmo predictivo de BCS de manera simultánea, incluso sin una sesión de calificación en curso.

4.3.3 Calificadores

Los calificadores reciben las imágenes mediante un sistema de colas JMS, que les permite acceder a los trabajos de calificación pendientes. El sistema gestiona estos trabajos de manera robusta, asegurando que no se pierdan datos en caso de interrupciones del sistema.

Para evaluar, los calificadores deben estar asociados a una sesión de calificación activa. Las imágenes de las vacas se envían únicamente si hay calificadores disponibles. El calificador accede a las imágenes mediante solicitudes GET a su cola asignada. Una vez

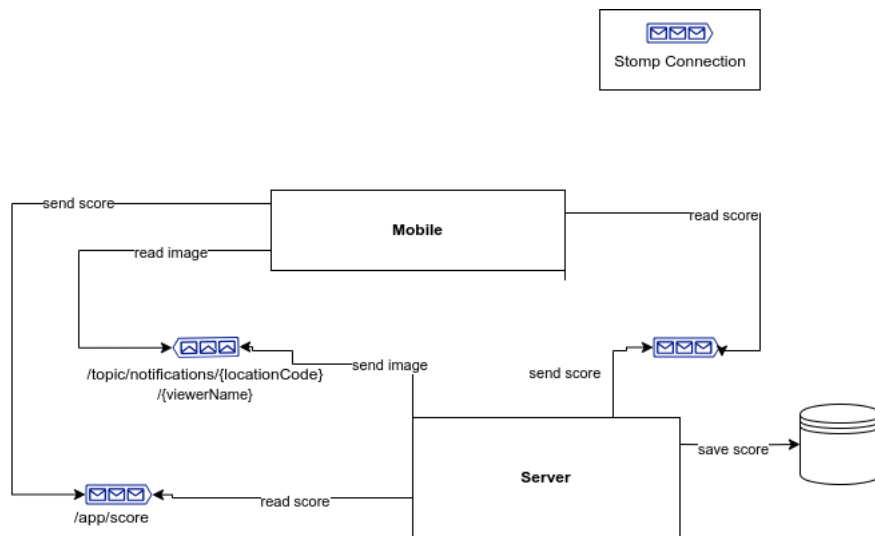


Figure 4.6: Diagrama de componentes - Observadores

evaluada una imagen, el puntaje BCS es enviado al servidor mediante una solicitud PUT, y el trabajo queda registrado en el sistema.

Este proceso asegura que las evaluaciones de los calificadores estén organizadas y almacenadas correctamente para su uso posterior, como el entrenamiento o mejoramiento de modelos predictivos de BCS.

4.3.4 Observador

En el diseño actual del prototipo, los observadores reciben las imágenes en tiempo real a través de websockets, conectados por defecto a una locación específica. A diferencia de los calificadores, los observadores no necesitan estar asociados a una sesión de calificación para visualizar las imágenes y ejecutar de forma automática el algoritmo predictivo BCS.

Actualmente, el cálculo del puntaje BCS se lleva a cabo exclusivamente en los dispositivos móviles de los observadores. Esto es debido a que el servidor no está diseñado para realizar este procesamiento. El sistema utiliza un enfoque de round-robin para seleccionar un observador de la lista de aquellos que tienen conexiones websocket abiertas, permitiendo que el dispositivo seleccionado realice la predicción del puntaje BCS. El resultado de esta predicción se envía al servidor y se distribuye a otros observadores en la misma locación a través de websocket, lo que permite que el puntaje BCS calculado sea visualizado en tiempo real en los dispositivos de todos los observadores activos.

Sin embargo, el diseño del sistema podría ser adaptado para que, en futuras versiones, el servidor pueda realizar estos cálculos, siempre y cuando se cuente con un hardware

adecuado para el procesamiento en tiempo real. En escenarios donde el servidor sea de bajo costo y con capacidades limitadas, se seguiría dependiendo de los dispositivos móviles para la ejecución del algoritmo. En cambio, si el servidor fuera actualizado a un hardware más potente, todo el procesamiento podría centralizarse allí, eliminando la necesidad de utilizar los dispositivos de los observadores.

En la versión actual, el puntaje calculado en los dispositivos móviles se envía al servidor y se distribuye a otros observadores en la misma locación a través de websocket. Así, el puntaje BCS se visualiza en tiempo real en los dispositivos de todos los observadores activos. Si no hay observadores disponibles al momento de capturar las imágenes, la vaca no obtendrá un puntaje predictivo, ya que el algoritmo de predicción debe ejecutarse en los dispositivos de los observadores.

Los observadores asignados ejecutan el algoritmo de predicción en sus dispositivos, y el puntaje calculado se envía a:

- Su pantalla: Para que puedan visualizar el resultado de inmediato.
- El servidor: Donde se almacena en la base de datos para su posterior análisis.
- Los demás observadores conectados: Para que también puedan ver el puntaje obtenido.

Si el planificador designa la tarea de predicción a otro observador, el dispositivo del observador inicial espera el resultado del puntaje BCS. Una vez que llega, el puntaje se muestra automáticamente en su pantalla, actualizando simultáneamente los reportes y visualizaciones.

Esta estructura garantiza que el flujo de imágenes, la predicción de BCS y la visualización por parte de los observadores se lleven a cabo de manera eficiente y sin interrupciones, independientemente de si hay sesiones activas.

Verificar y aclarar que solo se puede ver si no hay sesiones activas el número de predicción de la vaca y su historial dentro del sistema. Pero no se puede ver el reporte de la sesión hasta que no inicie esta..

4.4 Reportes

Cada opción de visualización de reportes, ya sea para sesiones actuales o reportes de sesiones anteriores, se accede mediante llamadas REST a la base de datos. Esta estructura permite que tanto observadores como calificadores obtengan la información necesaria cuando lo deseen. Es importante señalar que los reportes solo contienen los valores de las predicciones generadas por el sistema. Los calificadores no tienen acceso a los valores que ellos mismos u otros calificadores asignan a las vacas durante el proceso de calificación.

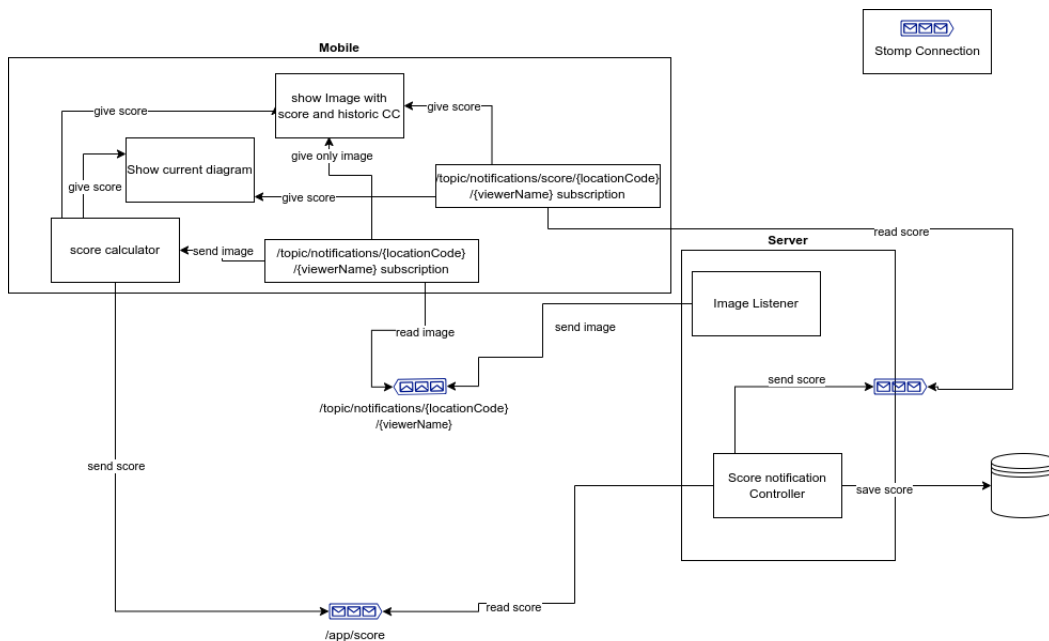


Figure 4.7: Diagrama de componentes - Observadores en detalle

- Actualización de estado en Tiempo Real: En las sesiones actuales, sólo los observadores reciben actualizaciones de las predicciones en tiempo real, lo que les permite actualizar el diagrama de torta automáticamente. Por otro lado, los calificadores no reciben estas actualizaciones en tiempo real, ya que su función principal es calificar las vacas. Sin embargo, pueden acceder a los datos en cualquier momento, ingresando a la sección de la aplicación donde se visualizan los reportes.
- Historial de BCS: Exclusivo para los observadores, el historial de BCS se obtiene mediante una llamada REST a la base de datos. Este diagrama se actualiza automáticamente con el valor predicho una vez que el cálculo del BCS para la sesión actual finaliza, garantizando que los observadores tengan acceso a la información más precisa y actualizada.

Esta arquitectura no solo facilita la visualización y el acceso a los reportes, sino que también asegura que tanto los observadores como los calificadores tengan la información necesaria para tomar decisiones informadas sobre la condición corporal de las vacas. En el futuro, la implementación de un apartador automático podría jugar el rol de observador y actuar habilitando diferentes puertas para apartar a las vacas de un rodeo que requieren una dieta o tratamiento especial basado en su valor de BCS.

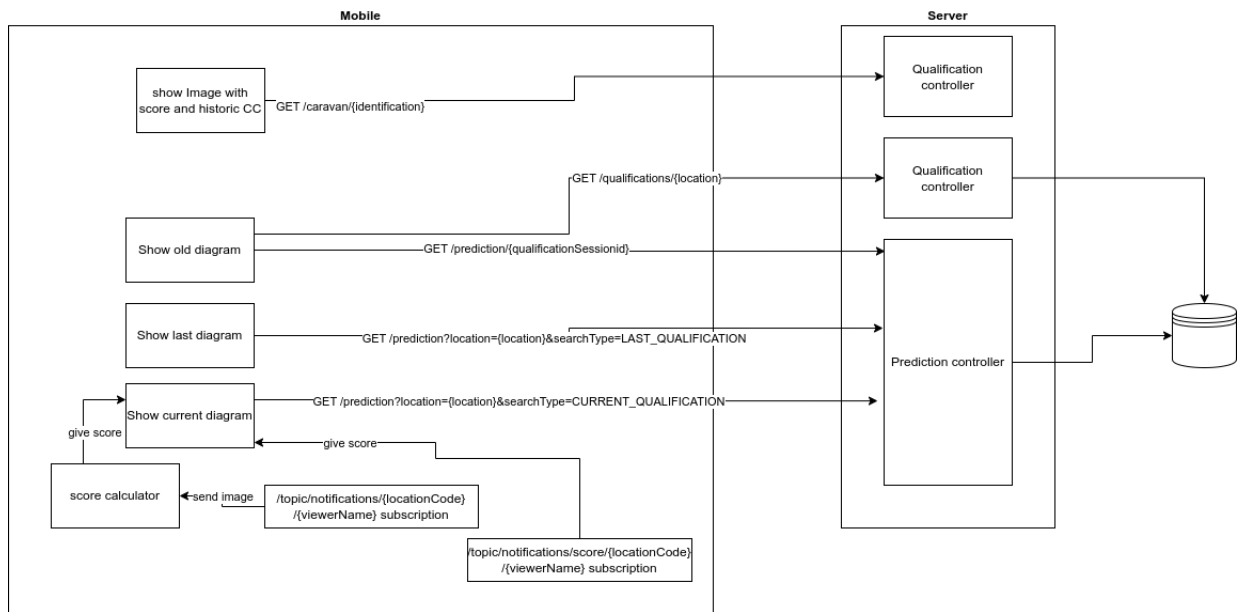


Figure 4.8: Diagrama de componentes - reporte de observadores

4.4.1 Observador

En el caso de los observadores, como se mencionó anteriormente, dado que es posible que los observadores estén mirando la pantalla de diagramas y dado que siempre recibe el BCS calculado (o por él mismo o por otro observador) se actualiza el diagrama automáticamente utilizando websocket y el protocolo STOMP.

Los observadores pueden ver los diagramas de torta que se actualizan automáticamente en tiempo real al recibir nuevas predicciones de BCS, ya sea realizadas por ellos mismos o por otros observadores. Además, pueden consultar el historial de BCS de vacas en sesiones anteriores cuando reciben una nueva imagen, lo que les permite comparar los datos actuales con los registros previos.

4.4.2 Calificador

En el caso de los calificadores, su función principal es evaluar las vacas, por lo que los diagramas se actualizan únicamente cuando deciden consultar los reportes a través de una llamada REST. Este enfoque permite que realicen las solicitudes cuando lo consideren necesario, evitando la necesidad de mantener una conexión websocket abierta para recibir notificaciones sobre las predicciones.

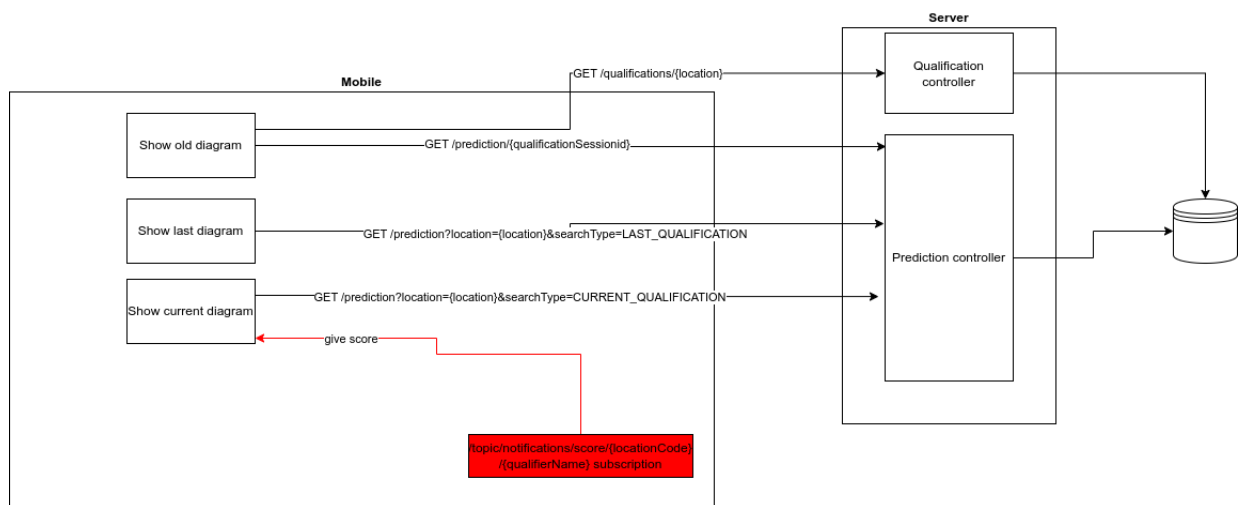


Figure 4.9: Diagrama de componentes - reporte de calificadores

4.5 Implementación

Esta sección describe las tecnologías, bibliotecas y configuraciones empleadas para desarrollar e implementar el prototipo. A continuación, se detallan los componentes principales, la configuración del sistema y el modelo de base de datos.

4.5.1 Tecnologías y Bibliotecas Utilizadas

- Servidor: El backend está desarrollado con Spring Boot para la creación del servidor, aprovechando Spring Web para implementar los servicios REST y el protocolo STOMP para la comunicación a través de WebSockets.
- Base de Datos: Se utiliza MySQL como base de datos relacional y JDBC para interactuar con ella.
- Mensajería: La integración de ActiveMQ con JMS facilita la comunicación asincrónica y garantiza la disponibilidad de los mensajes entre los distintos componentes.
- Aplicación Móvil: La aplicación está desarrollada en Flutter para Android, con capacidad de expansión hacia iOS. Esto permite la posibilidad de adaptaciones para dispositivos iOS en el futuro.

4.5.2 Configuración del sistema

Este apartado explicará cómo se configuran los diversos componentes del sistema, incluidos el servidor, base de datos y las dependencias necesarias para que el sistema funcione

correctamente.

4.5.2.1 Configuración del Servidor

1. Antes de proceder con cualquiera de las opciones, asegúrate de tener instalado:
 - (a) Java 11: Es obligatorio para ejecutar la aplicación. Puedes verificar tu versión de Java ejecutando el siguiente comando: `java -version`
Si no tienes Java 11, puedes instalarlo desde el sitio oficial de Oracle o mediante un gestor de paquetes como apt, brew, o sdkman.
 - (b) Maven (si vas a compilar desde el código fuente): Para compilar el proyecto si tienes acceso al código fuente.
 - (c) En ubuntu/Debian: `sudo apt install maven`
 - (d) En macOS con Homebrew: `brew install maven`
2. Configuración de MySQL
 - (a) Descargar e instalar MySQL
 - i. Descarga MySQL 8.0
 - ii. Instalarlo siguiendo las instrucciones del asistente.
 - (b) Configurar MySQL
 - i. Una vez instalado, iniciar el servidor MySQL
 - A. macOS o Linux: `mysql.server start`
 - B. windows: `net start mysql`
 - (c) Acceder a MySQL
 - i. Abre el cliente de MySQL: `mysql -u root -p`
 - ii. CXuando se te solicite, introduce la contraseña de root
 - (d) Crear la base de datos
 - i. Ejecuta el siguiente comando para crear el esquema necesario: `CREATE SCHEMA server`
3. Descarga ActiveMQ Artemis
 - (a) Ve al sitio oficial de ActiveMQ Artemis
 - (b) Descarga la última versión del broker
 - (c) Instalar ActiveMQ Artemis
 - (d) Descomprime el archivo descargado en un directorio de tu elección.
 - (e) Ve al directorio bin dentro de la carpeta de ActiveMQ Artemis.

- (f) Ejecuta el siguiente comando para crear una nueva instancia del broker.
`./artemis create mybroker --user admin --password admin`
- (g) Esto creará una instancia de ActiveMQ con el nombre mybroker
- 4. Iniciar el broker
 - (a) Ve al directorio mybroker/bin y ejecuta: `./artemis run`
- 5. El broker estará corriendo por defecto en el puerto 6161

4.5.2.2 Configuración de la aplicación móvil

En esta sección se detallará cómo configurar la aplicación móvil desarrollada con Flutter para interactuar con el sistema.

1. Host y Puerto del Servidor: La configuración del host y puerto de servidor se ajusta en las variables serverHost y serverPort. Por defecto:
 - (a) localhost en iOS y 10.0.2.2 en Android para entornos de emulación.
 - (b) Puerto 8080 si no se especifica otro.
2. Configuración de escritura:

Para que la aplicación pueda acceder y escribir en el sistema de archivos, sigue estos pasos.

 - (a) Copiar archivo de imagen: Copia el archivo empty_image.png ubicado en la carpeta assets de la aplicación al directorio sdcard/Download/ en el emulador o dispositivo Android.
 - (b) Para permitir que la aplicación móvil interactúe con el sistema de archivos del dispositivo Android, se deben realizar las siguientes configuraciones:
 - i. Copiar el archivo assets/empty_image.png al directorio sdcard/Download/ del emulador o dispositivo Android.
 - ii. Asegurarse de que la aplicación tenga permisos de escritura en el sistema de archivos del dispositivo. Esto se puede configurar desde los ajustes del emulador o del dispositivo Android en la opción de permisos de la aplicación calificador.
 - iii. La aplicación depende de un entorno Python 3.8 para ejecutar scripts específicos. Para configurar el entorno Python:
 - (c) Definir la ruta de Python 3.8 en el sistema:
 - i. Para sistemas Linux:
 - A. `export PYTHON_3_8_HOME='/home/linuxbrew/.linuxbrew/opt/python@3.8/bin'`
 - B. `export PATH=$PATH:$PYTHON_3_8_HOME`

4.5.2.3 Configuración de docker

Opcionalmente, puedes configurar todos los servicios a través de contenedores Docker para simplificar la instalación y configuración (recomendado para ambientes de desarrollo).

Para iniciar el servicio de mensajería en un contenedor Docker con ActiveMQ Artemis, ejecuta el siguiente comando:

```
docker run -p 61616:61616 -e AMQ_USER=admin -e AMQ_PASSWORD=admin quay.io/artemiscloud/activemq-artemis-broker
```

Este comando configura el broker de mensajería en el puerto 61616.

Luego, inicia la base de datos MySQL en un contenedor Docker con el siguiente comando:

```
docker run --name=mysql-db -e MYSQL_ROOT_PASSWORD=root -p 3306:3306 mysql:8.0
```

Una vez que el contenedor esté en funcionamiento, accede a MySQL y crea el esquema necesario para el sistema:

```
docker exec -it mysql-db mysql -p
```

Cuando se te solicite la contraseña, introduce root y luego ejecuta el siguiente comando para crear el esquema:

```
CREATE SCHEMA server;
```

4.5.3 Modelo de base de datos

La base de datos utiliza el siguiente modelo relacional, implementado en MySQL para gestionar los datos de las sesiones de calificación y sus componentes.

1. Tabla LOCATION: Define las ubicaciones físicas en las que se realizan las calificaciones.

```
CREATE TABLE
server.LOCATION (
  ID INT AUTO_INCREMENT PRIMARY KEY,
  CODE VARCHAR(20),
  NAME VARCHAR(100)
);
```

2. Tabla QUALIFICATION_SESSION: Registra las sesiones de calificación realizadas en una ubicación específica, asociando cada sesión con su locación.

```
CREATE TABLE server.QUALIFICATION_SESSION (
  ID BIGINT AUTO_INCREMENT PRIMARY KEY,
```

```

LOCATION_ID INT NOT NULL,
START_DATE TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
END_DATE TIMESTAMP NULL,
CONSTRAINT fk_QUALIFICATION_SESSION_LOCATION_ID FOREIGN KEY (LOCATION_ID) REFERENCES LOCATION (ID)
);

```

3. Tabla LOCATION_QUALIFICATION_SESSION: Sesiones activas en cada locación

```

CREATE TABLE server.LOCATION_QUALIFICATION_SESSION(
QUALIFICATION_SESSION_ID BIGINT,
LOCATION_ID INT,
CONSTRAINT pk_LOCATION_QUALIFICATION_SESSION PRIMARY KEY(LOCATION_ID),
CONSTRAINT 'fk_LOCATION_QUALIFICATION_SESSION_LOCATION_ID' FOREIGN KEY('LOCATION_ID') REFERENCES 'LOCATION'('ID'),
CONSTRAINT 'fk_LOCATION_QUALIFICATION_SESSION_QUALIFICATION_SESSION_ID' FOREIGN KEY('QUALIFICATION_SESSION_ID') REFERENCES 'QUALIFICATION_SESSION'('ID')
);

```

4. Tabla USER: Almacena la información de los usuarios registrados en el sistema y asegura nombres de usuario únicos.

```

CREATE TABLE server.USER (
ID INT AUTO_INCREMENT PRIMARY KEY,
USER_NAME VARCHAR(100),
TYPE VARCHAR(20),
CONSTRAINT uk_USER_USER_NAME UNIQUE (USER_NAME)
);

```

5. Tabla USER_QUALIFICATION_SESSION: Usuarios asociados a la sesión de calificación.

```

CREATE TABLE server.USER_QUALIFICATION_SESSION( USER_ID INT, QUALIFICATION_SESSION_ID BIGINT, PRIMARY KEY(USER_ID,QUALIFICATION_SESSION_ID),
CONSTRAINT 'fk_USER_QUALIFICATION_SESSION_QUALIFICATION_SESSION_ID' FOREIGN KEY('QUALIFICATION_SESSION_ID') REFERENCES 'QUALIFICATION_SESSION'('ID'),
CONSTRAINT 'fk_USER_QUALIFICATION_SESSION_USER_ID' FOREIGN KEY('USER_ID') REFERENCES 'USER'('ID')
);

```

6. Tabla USER_LOCATION_QUALIFICATION_SESSION: Usuarios registrados en la sesión de calificación actual.

```

CREATE TABLE server.USER_LOCATION_QUALIFICATION_SESSION(
USER_ID INT PRIMARY KEY,

```

```

QUALIFICATION_SESSION_ID BIGINT,
CONSTRAINT UNIQUE (USER_ID),
CONSTRAINT 'fk_USER_LOCATION_QUALIF_SESSION_USER_QUALIF_SESSION'
FOREIGN KEY('USER_ID','QUALIFICATION_SESSION_ID') REFERENCES 'USER_QUALIFICA
CONSTRAINT 'fk_USER_LOCATION_QUALIFICATION_SESSION_QUALIFICATION_SESSION
FOREIGN KEY('QUALIFICATION_SESSION_ID') REFERENCES 'LOCATION_QUALIFICATION
CONSTRAINT 'fk_USER_LOCATION_QUALIFICATION_SESSION_USER_ID' FOR-
EIGN KEY('USER_ID') REFERENCES 'USER'('ID')
);

```

7. Tabla IMAGE_SET: Representa conjuntos de imágenes relacionados a una sesión de calificación en una locación. Esta tabla contiene un identificador único (SET_CODE) que agrupa las imágenes realizadas para una caravana específica, permitiendo su agrupamiento y trazabilidad.

```

CREATE TABLE IMAGE_SET (
ID BIGINT AUTO_INCREMENT PRIMARY KEY,
SET_CODE VARCHAR(36) UNIQUE,
);

```

8. Tabla IMAGE_SET_LOCATION: Conjuntos de imágenes actuales de una caravana en una locación.

```

CREATE TABLE server.IMAGE_SET_LOCATION(
IMAGE_SET_ID BIGINT PRIMARY KEY,
LOCATION_ID INT,
CREATION_DATE TIMESTAMP NOT NULL DEFAULT CURRENT_TIMESTAMP,
'POSITION' SMALLINT NOT NULL,
CONSTRAINT uk_IMAGE_SET_LOCATION_POSITION UNIQUE('LOCATION_ID','POSITION
CONSTRAINT fk_IMAGE_SET_LOCATION_LOCATION_ID FOREIGN KEY('LOCATION_ID')
REFERENCES 'LOCATION'('ID'),
CONSTRAINT fk_IMAGE_SET_LOCATION_SET_ID FOREIGN KEY('IMAGE_SET_ID')
REFERENCES 'IMAGE_SET'('ID'),
CONSTRAINT nn_IMAGE_SET_LOCATION_LOCATION_ID CHECK('LOCATION_ID'
is NOT NULL)
);

```

9. Tabla IMAGE_SET_QUALIFICATION_SESSION Conjuntos de imágenes de una sesión de calificación.

```

CREATE TABLE server.IMAGE_SET_QUALIFICATION_SESSION(
IMAGE_SET_ID BIGINT PRIMARY KEY,
QUALIFICATION_SESSION_ID BIGINT NOT NULL,
CONSTRAINT fk_IMAGE_SET_QUALIFICATION_SESSION_SET_ID FOREIGN KEY('IMAGE_S

```

```
REFERENCES 'IMAGE_SET'('ID'),
CONSTRAINT 'fk_IMAGE_SET_QUALIFICATION_SESSION_ID' FOREIGN KEY('QUALIFICATION_
REFERENCES 'QUALIFICATION_SESSION'('ID')
);
```

10. Tabla IMAGE que contiene una columna llamada prioridad que será enviada al calificador y al observador y el path se construye con el Directorio mas nombre del archivo.

```
CREATE TABLE server.IMAGE(
ID BIGINT NOT NULL AUTO_INCREMENT PRIMARY KEY,
IMAGE_SET_ID BIGINT NOT NULL,
PRIORITY INT NULL COMMENT ,
'PATH' VARCHAR(500) NULL UNIQUE COMMENT,
CONSTRAINT 'fk_IMAGE_SET_ID' FOREIGN KEY ('IMAGE_SET_ID') REFER-
ENCES IMAGE_SET ('ID')
);
```

11. Tabla PREDICTED_SCORE Puntaje para una caravana en una sesión dada definido por el algoritmo de predicción.

```
CREATE TABLE server.PREDICTED_SCORE(
IMAGE_SET_ID BIGINT NOT NULL PRIMARY KEY ,
SCORE DECIMAL(5, 4) NOT NULL,
QUALIFICATION_SESSION_ID BIGINT NULL,
CONSTRAINT 'fk_PREDICTED_SCORE_SET_ID' FOREIGN KEY ('IMAGE_SET_ID')
REFERENCES 'IMAGE_SET' ('ID'),
CONSTRAINT 'fk_PREDICTED_SCORE_QUALIFICATION_SESSION_ID' FOREIGN
KEY('QUALIFICATION_SESSION_ID') REFERENCES 'QUALIFICATION_SESSION'('ID')
);
```

12. Tabla QUALIFIED_SCORE: Guarda las puntuaciones otorgadas a los conjuntos de imágenes en cada sesión de calificación. La tabla QUALIFIED_SCORE almacena el puntaje definido por el calificador para una caravana en una sesión específica. La puntuación va de 1 a 5. Los valores de puntaje están restringidos para asegurar que se mantengan dentro de un rango de calificación válido.

```
CREATE TABLE server.QUALIFIED_SCORE (
USER_ID INT,
QUALIFICATION_SESSION_ID BIGINT,
IMAGE_SET_ID BIGINT NOT NULL,
SCORE SMALLINT NOT NULL,
PRIMARY KEY (USER_ID, QUALIFICATION_SESSION_ID, IMAGE_SET_ID),
CONSTRAINT fk_QUALIFIED_SCORE_USER_QUALIFICATION_SESSION FOR-
```



```

EIGN KEY (USER_ID, QUALIFICATION_SESSION_ID) REFERENCES USER_QUALIFICATION_
(USER_ID, QUALIFICATION_SESSION_ID),
CONSTRAINT fk_QUALIFIED_SCORE_SET_ID FOREIGN KEY (IMAGE_SET_ID)
REFERENCES IMAGE_SET (ID),
CONSTRAINT CHK_QUALIFIED_SCORE_SCORE_MIN CHECK (SCORE > 0),
CONSTRAINT CHK_QUALIFIED_SCORE_SCORE_MAX CHECK (SCORE <= 5)
);
```

Resultados

En este capítulo, se presentan las capturas de pantalla y el análisis de las principales interfaces de usuario de cada caso de uso, proporcionando una evaluación del funcionamiento y la usabilidad de cada módulo en la aplicación.

5.1 Pantalla de Inicio de Sesión (Login)

El módulo de inicio de sesión permite a los usuarios acceder al sistema con distintos roles, con diferentes permisos y funciones dentro de la aplicación. La pantalla principal de acceso ofrece dos opciones: "Iniciar sesión" y "Registrar usuario", de modo que el usuario puede elegir entre ingresar al sistema o registrarse como nuevo usuario, según sea necesario.

[Acá va imagen de la pantalla principal de acceso]

Si el usuario selecciona "Iniciar sesión", es dirigido a una pantalla donde puede introducir su nombre de usuario. En caso de un ingreso correcto, el sistema autentica el perfil y redirige al usuario a su módulo correspondiente, ya sea como calificador o como observador.

[Acá va imagen de la pantalla de ingreso de usuario]

En cambio, si el usuario selecciona "Registrar usuario", el sistema muestra una pantalla donde el usuario puede introducir su nombre y seleccionar su rol (calificador u observador). Esta pantalla permite que los nuevos usuarios definan adecuadamente su perfil dentro de la aplicación. Una vez completado el registro, el sistema redirige automáticamente al usuario a la pantalla de inicio de sesión para facilitar el acceso.

[Acá va imagen de la pantalla de registro de usuario]

La interfaz de inicio de sesión presenta mensajes de error en caso de datos incorrectos o problemas de conexión con el servidor. El sistema está configurado para gestionar el acceso según el rol del usuario, asegurando que cada perfil (calificador u observador) acceda exclusivamente a las funciones asignadas.

5.2 Calificador

El módulo de calificación permite al usuario con rol de calificador gestionar sus sesiones de calificación de manera eficiente. Desde esta pantalla, el calificador puede iniciar una nueva sesión de calificación o finalizar una sesión previamente activa, asegurando que solo una sesión esté abierta a la vez.

[Acá va imagen de la pantalla de inicio de sesión de calificador]

Si el calificador intenta iniciar una nueva sesión mientras otra está activa, el sistema muestra mensajes de error claros e informativos, indicando la necesidad de finalizar la sesión actual antes de comenzar una nueva. Esta funcionalidad garantiza el control adecuado del flujo de trabajo del calificador, evitando conflictos o superposición de datos.

En el caso de iniciar sesión, la aplicación los redirige a la pantalla principal del calificador.

En la sesión de calificación, los usuarios calificadores pueden asignar puntajes a las imágenes de las caravanas en base a criterios predefinidos. Esta funcionalidad es fundamental para la recopilación y almacenamiento de datos de evaluación.

[Acá va imagen de la pantalla de sesión de calificación]

5.3 Sistema de Notificación de Imágenes

El módulo del observador, tras iniciar sesión, redirige automáticamente al usuario a la pantalla principal, diseñada para recibir y mostrar las imágenes a medida que son enviadas al sistema. Este módulo permite a los usuarios con el rol de observador visualizar las imágenes capturadas de las caravanas junto con su identificación asociada.

Además, una vez que se calcula el puntaje de condición corporal (BCS) predicho, ya sea por este observador u otro, el resultado se muestra en la misma pantalla. También se proporciona acceso al historial de dicha caravana, permitiendo revisar las evaluaciones realizadas en sesiones anteriores.

La interfaz del observador es completamente de solo lectura, sin opciones para interactuar o realizar modificaciones. Las imágenes de las caravanas se actualizan de manera automática conforme las vacas pasan frente a la cámara, ofreciendo una experiencia fluida y enfocada en la visualización y monitoreo en tiempo real.

[Acá va imagen de la pantalla del observador]

Por otro lado, el módulo del calificador redirige automáticamente al usuario, tras iniciar sesión de calificación, a su pantalla principal. Esta interfaz está diseñada para permitir que el calificador avance manualmente a la siguiente imagen de una vaca haciendo clic en el botón "Siguiendo". Esto le da al calificador el control de cuándo visualizar la próxima imagen para asignar el valor BCS correspondiente. Es importante destacar que el calificador debe interactuar activamente con la aplicación para avanzar o esperar la llegada de una nueva imagen.

[Acá va imagen de la pantalla del calificador]

En la pantalla principal, ambos usuarios tienen acceso a un menú que les permite cerrar la sesión. Además, para los calificadores, este menú incluye la opción adicional de finalizar una sesión de calificación en curso.

[Acá va imagen del menu]

5.4 Reportes Generados

Tanto los calificadores como los observadores cuentan con herramientas visuales que facilitan el análisis de los datos generados durante las sesiones de calificación. Entre estas herramientas destaca un gráfico de tipo torta, que proporciona una representación clara y organizada de las sesiones en curso y las completadas. Este gráfico agrupa los valores predichos del puntaje de condición corporal (BCS) en categorías enteras del 1 al 5, basándose en la parte entera del valor incluso cuando la predicción incluye decimales. Esta metodología asegura una visualización uniforme, intuitiva y de fácil interpretación para todos los usuarios.

Adicionalmente, se incluye un diagrama de dispersión que muestra el promedio del puntaje de condición corporal (BCS) de las sesiones anteriores, ofreciendo una perspectiva comparativa y útil para evaluar tendencias a lo largo del tiempo.

5.5 Rendimientos del sistema

Para evaluar la eficiencia del sistema, se midieron los tiempos de predicción del BCS en un móvil. Estos tiempos son críticos para garantizar una experiencia fluida en obtener los resultados de la predicción para que el observador puede visualizarlos y para que tanto el calificador como el observador puedan visualizar los reportes en tiempo real.

5.5.1 Tiempos de Predicción

El tiempo promedio de predicción para una imagen fue de X segundos, con una desviación estándar de Y segundos. Este rendimiento asegura que el sistema puede procesar imágenes en tiempo real sin retrasos significativos, incluso bajo carga sostenida.

Comparación de Rendimiento

El sistema se comparó con otros enfoques de predicción utilizados en contextos similares, obteniendo los siguientes resultados:

Método/Modelo	Tiempo Promedio (segundos)	Precisión (%)
---------------	----------------------------	---------------

Nuestro Sistema	X	Y
-----------------	---	---

Método Competidor A	X1	Y1
---------------------	----	----

Método Competidor B	X2	Y2
---------------------	----	----

Los resultados muestran que nuestro sistema no solo es competitivo en términos de tiempo de predicción, sino que también mantiene una precisión aceptable para los fines del análisis.

Conclusión El análisis de rendimiento confirma que el sistema implementado logra un balance óptimo entre velocidad y precisión, lo cual es fundamental para las necesidades prácticas de los usuarios. Esto refuerza su idoneidad para ser utilizado en aplicaciones en tiempo real, como la calificación de imágenes en la plataforma desarrollada.

Conclusiones, Limitaciones y Trabajos Futuros

6.1 Login

En futuras implementaciones puede agregarse una capa de seguridad para el login debido a que actualmente solo se creó este componente para poder definir el tipo de usuario y asociar una calificación de una vaca a un determinado experto.

Además, en futuras implementaciones puede ser posible limitar que personas pueden registrarse como calificador debido a que una sola aplicación móvil soporta un usuario calificador y observador, cualquier persona puede registrarse como calificador sin ser un experto.

6.2 Calificador

En futuras versiones del server va a ser posible que los calificadores compartan la misma cola jms para repartirse la calificación y darse de baja de una sesión de calificación y conectarse a otra. Otra posibilidad para futuras versiones es que la sesión pueda configurarse para que los usuarios calificadores se repartan las caravanas a calificar. Para lograr esto va a ser necesario que la sesión de calificación tenga un tipo de calificación identificando pueden repartirse entre calificadores o que todos los calificadores puedan calificar todas las vacas.

6.3 Arribo de imágenes de vacas

El server tiene la posibilidad de recibir y almacenar un conjunto de imágenes por cada vaca pero solo la primera será la que el observador y el calificador reciban. Queda para futuros proyectos la posibilidad de enviar todas las imágenes a los calificadores y/o observadores.

6.4 Aplicación batch

Esta aplicación se definió para este proyecto pero queda fuera de alcance de este trabajo. La aplicación batch deberá tener una locación preconfigurada que será utilizada para notificar al server de donde proviene el job. Leerá las imágenes tomadas a la vaca, armará el job y lo enviará al server. Este procedimiento por cada vaca. La cantidad de imágenes a tomar serán configuración de la aplicación batch. La primera imagen de cada job (elemento 0 de la lista) se va a suponer que va a poseer el número de caravana, por lo tanto, está imagen (la primera de la lista) es la única que se enviará al calificador a la hora de calificar y al observador.

6.5 Calificador

Los calificadores no pueden calificar job anteriores a la unión/creación de la sesión de calificación, es decir, que los jobs que existan antes del inicio de sesión no serán calificados por nadie. Aquellos que arriben antes de que un calificador se una a una sesión de calificación tampoco van a ser calificados.

Para lograr que los jobs generados antes del inicio de sesión de calificación o antes de que el usuario se uniera a una sesión existente se envíen a la cola de calificación de cada usuario va a ser necesario que cuando se inicia sesión de calificación se carguen todos los jobs desde la base de datos en la locación específica de la sesión a la cola jms del usuario. Esto puede provocar que:

- si se crea la cola del usuario calificador y luego se asigna a la sesión, mientras se envíen los jobs desde la base a la cola, puedan llegar nuevos job y se ubiquen antes de los jobs de la base.
- si se crea la cola del usuario calificador, se agregan los jobs de la base a la cola y luego se asigna a la sesión de calificación, pueden llegar job nuevos que no fueron leídos de la base y que tampoco se haya enviado a la cola porque no se había asignado a la sesión.

6.6 Observadores

La predicción de la CC es realizada por los observadores, es decir, es realizada en la aplicación móvil. Si no hay observadores no es posible realizar la predicción. Para poder realizarla sin la necesidad de observadores se ejecuta el algoritmo de predicción en los calificadores y también es posible implementar el algoritmo de predicción en el server para que realice la predicción de aquellos jobs que no fueron entregados para predecir o que hayan fallado para lograr que no haya jobs sin predecir.

6.7 Objetivos futuros

En cuanto al objetivo 4 ??, se ampliará el estudio de mercado inicial que acompaña a este proyecto, además diagramando el núcleo del modelo de negocios a desarrollar sobre la base de licenciamiento de registros.

Los modelos de CC validados serán desplegados en los dispositivos electrónicos, con su respectiva caja y estructura de caño para poder ser montado en cualquier establecimiento agropecuario (Objetivo 4). Este dispositivo integral será evaluado en al menos dos establecimientos de la zona, donde se evaluará no sólo el comportamiento predictivo del modelo, sino también su facilidad de uso e integración a las actividades diarias del/la profesional o el/la productor/a. En ese sentido (Objetivo 5 ??), se realizará una reunión de profesionales y productores en alguno de los sitios de pruebas, y bajo el formato de taller y con encuestas individuales se registrarán sus opiniones sobre las posibles barreras de adopción de estas tecnologías, así como sugerencias de mejoras. Adicionalmente, se trabajará con la especialista colaboradora, en la identificación de las mejores estrategias para el plan de negocios (clientes profesionales/productores, socios claves, precio de mercado etc).

MOVIDO DEL CAPÍTULO 3. ARREGLAR

- Integración IoT: El sistema debe ser extensible y preparado para integrarse en un entorno IoT. Esto implica el desarrollo de una capa de comunicación flexible que permita conectar diferentes dispositivos y elementos del entorno ganadero (como mangas, corrales, y comederos) a una red. Estos dispositivos deben ser capaces de realizar captura automatizada de datos y comunicar acciones de contingencia (CAC), estructurándose como un Sistema Integral de Gestión de la Información (SIGI) para facilitar el monitoreo, planificación, y toma de decisiones.

Bibliography

- R. S. Alonso, I. Sittón-Candanedo, Ó. García, J. Prieto, and S. Rodríguez-González. An intelligent edge-iot platform for monitoring livestock and crops in a dairy farming scenario. *Ad Hoc Networks*, 98:102047, 2020.
- J. R. Alvarez, M. Arroqui, P. Mangudo, J. Toloza, D. Jatip, J. M. Rodríguez, A. Teyseyre, C. Sanz, A. Zunino, C. Machado, et al. Body condition estimation on cows from depth images using convolutional neural networks. *Computers and electronics in agriculture*, 155:12–22, 2018.
- N. Apolónia, F. Freitag, and L. Navarro. Leveraging deployment models on low-resource devices for cloud services in community networks. *Simulation Modelling Practice and Theory*, 77:390–406, 2017.
- A. Aquino, I. Barrio, M.-P. Diago, B. Millan, and J. Tardaguila. vitisberry: An android-smartphone application to early evaluate the number of grapevine berries by means of image analysis. *Computers and Electronics in Agriculture*, 148:19–28, 2018.
- J. Bao and Q. Xie. Artificial intelligence in animal farming: A systematic literature review. *Journal of Cleaner Production*, 331:129956, 2022.
- K. K. Çevik. Deep learning based real-time body condition score classification system. *IEEE Access*, 8:213950–213957, 2020.
- J. De Hagen, R. Chayer, C. Machado, O. Melluci, and R. Catalano. Estudio de la asociación entre la respuesta reproductiva y el estado corporal evaluado al momento del diagnóstico de gestación en bovinos. 2010.
- A. Fischer, T. Luginbühl, L. Delattre, J. Delouard, and P. Faverdin. Rear shape in 3 dimensions summarized by principal component analysis is a good predictor of body condition score in holstein dairy cows. *Journal of dairy science*, 98(7):4465–4476, 2015.

- M. Gusev and Y. Wang. Formal description of dew computing. In *Proceedings of The 3rd International Workshop on Dew Computing*, pages 8–13, 2018.
- M. Hirsch, J. M. Rodriguez, C. Mateos, and A. Zunino. A two-phase energy-aware scheduling approach for cpu-intensive jobs in mobile grids. *Journal of Grid Computing*, 15:55–80, 2017.
- M. Hirsch, C. Mateos, and A. Zunino. Augmenting computing capabilities at the edge by jointly exploiting mobile devices: A survey. *Future Generation Computer Systems*, 88: 644–662, 2018.
- M. Hirsch, C. Mateos, J. M. Rodriguez, and A. Zunino. Dewsim: A trace-driven toolkit for simulating mobile device clusters in dew computing environments. *Software: Practice and Experience*, 50(5):688–718, 2020.
- C.-H. Hong and B. Varghese. Resource management in fog/edge computing: a survey on architectures, infrastructure, and algorithms. *ACM Computing Surveys (CSUR)*, 52(5):1–37, 2019.
- A. Kamilaris and F. X. Prenafeta-Boldú. Deep learning in agriculture: A survey. *Computers and electronics in agriculture*, 147:70–90, 2018.
- S. Kumar, A. Pandey, K. S. R. Satwik, S. Kumar, S. K. Singh, A. K. Singh, and A. Mohan. Deep learning framework for recognition of cattle using muzzle point image pattern. *Measurement*, 116:1–17, 2018.
- T. Kurita. Principal component analysis (pca). *Computer vision: a reference guide*, pages 1–4, 2019.
- J. Li, J. Fang, Y. Fan, and C. Zhang. Design on the monitoring system of physical characteristics of dairy cattle based on zigbee technology. In *2010 World Automation Congress*, pages 63–66. IEEE, 2010.
- M. S. Mahmud, A. Zahid, A. K. Das, M. Muzammil, and M. U. Khan. A systematic literature review on deep learning applications for precision cattle farming. *Computers and Electronics in Agriculture*, 187:106313, 2021.
- S. Maresca, J. Quiroz García, G. Melani, J. Burges, G. Brusca, and F. Plorutti. El estado corporal y su efecto en la eficiencia reproductiva en rodeos de cría de la cuenca del salado. *Publicación Técnica INTA*, (3), 2008.
- G. Masferrer, R. Carreras, M. Font-i Furnols, M. Gispert, P. Marti-Puig, and M. Serra. On-line ham grading using pattern recognition models based on available data in commercial pig slaughterhouses. *Meat science*, 143:39–45, 2018.

- P.-A. Morin, Y. Chorfi, J. Dubuc, J.-P. Roy, D. Santschi, and S. Dufour. An observational study investigating inter-observer agreement for variation over time of body condition score in dairy cows. *Journal of Dairy Science*, 100(4):3086–3090, 2017.
- A. Nasirahmadi, B. Sturm, A.-C. Olsson, K.-H. Jeppsson, S. Müller, S. Edwards, and O. Hensel. Automatic scoring of lateral and sternal lying posture in grouped pigs using image processing and support vector machine. *Computers and electronics in agriculture*, 156:475–481, 2019.
- G. P. Piedade, S. B. Mafra, D. M. de Oliveira, and M. R. da Cruz. Design, deployment, and validation of a low-cost iot platform based on lora for precision dairy farming.
- F. J. Prego, L. Nieto, M. Solla, and I. Puente. A mobile android tool for simplified gpr data processing in construction applications. *Automation in Construction*, 89:170–182, 2018.
- M. Richards, J. Spitzer, and M. Warner. Effect of varying levels of postpartum nutrition and body condition at calving on subsequent reproductive performance in beef cattle. *Journal of Animal Science*, 62(2):300–306, 1986.
- M. Riekert, A. Klein, F. Adrion, C. Hoffmann, and E. Gallmann. Automatically detecting pig position and posture by 2d camera imaging and deep learning. *Computers and Electronics in Agriculture*, 174:105391, 2020.
- A. Rindos and Y. Wang. Dew computing: The complementary piece of cloud computing. In *2016 IEEE International Conferences on Big Data and Cloud Computing (BDCloud), Social Computing and Networking (SocialCom), Sustainable Computing and Communications (SustainCom)(BDCloud-SocialCom-SustainCom)*, pages 15–20. IEEE, 2016.
- J. R. Roche, N. C. Friggens, J. K. Kay, M. W. Fisher, K. J. Stafford, and D. P. Berry. Invited review: Body condition score and its association with dairy cow productivity, health, and welfare. *Journal of dairy science*, 92(12):5769–5801, 2009.
- J. M. Rodríguez Álvarez, M. Arroqui, P. Mangudo, J. M. Toloza, D. E. Jatip, J. M. Rodríguez, A. O. Zunino Suarez, C. Mateos, and C. Machado. Revisión y análisis de técnicas y métodos computacionales para la evaluación de la condición corporal en vacas. 2018.
- G. Selk, R. Wettemann, K. Lusby, J. Oltjen, S. Mobley, R. Rasby, and J. Garmendia. Relationships among weight change, body condition and reproductive performance of range beef cows. *Journal of animal science*, 66(12):3153–3159, 1988.
- A. Singh, B. Ganapathysubramanian, A. K. Singh, and S. Sarkar. Machine learning for high-throughput stress phenotyping in plants. *Trends in plant science*, 21(2):110–124, 2016.

- G. Singh, D. Bansal, S. Sofat, and N. Aggarwal. Smart patrolling: An efficient road surface monitoring using smartphone sensors and crowdsourcing. *Pervasive and Mobile Computing*, 40:71–88, 2017.
- K. Skala, D. Davidovic, E. Afgan, I. Sovic, and Z. Sojat. Scalable distributed computing hierarchy: Cloud, fog and dew computing. *Open Journal of Cloud Computing (OJCC)*, 2(1):16–24, 2015.
- E. Wildman, G. Jones, P. Wagner, R. Boman, H. Troutt Jr, and T. Lesch. A dairy cow body condition scoring system and its relationship to selected production characteristics. *Journal of dairy science*, 65(3):495–501, 1982.
- C.-J. Yang, Y.-H. Lin, and S.-Y. Peng. Develop a video monitoring system for dairy estrus detection at night. In *2017 International Conference on Applied System Innovation (ICASI)*, pages 1900–1903. IEEE, 2017.
- S. Yukun, H. Pengju, W. Yujie, C. Ziqi, L. Yang, D. Baisheng, L. Runze, and Z. Yonggen. Automatic monitoring system for individual dairy cows based on a deep learning framework that provides identification via body parts and estimation of body condition score. *Journal of dairy science*, 102(11):10140–10151, 2019.